Rapport de stage

Développement d'une méthode automatique de sélection de variables dans les procédés de formulation chimique.

Mastère Spécialisé

Calcul hautes performances/Données massives /Intelligence artificielle

Stagiaire :
Paul Diokine BATISTA
Encadreur :
Ph.D Abdou KANE CEO InFLOWS AI

1er septembre 2023

Table des matières

1 Introduction générale **7**
1.1 Présentation d'InFLOWS AI : Intelligent Process Flows . . . 7
1.2 Problématique industrielle de la Chimie de Formulation . . . 8
1.2.1 Définition de la chimie de formulation . . . 8
1.2.2 Problèmes de la chimie de formulation . . . 8
1.3 Méthodes statistiques et d'apprentissages statistiques . . . 9
1.3.1 Plans d'expériences . . . 9
1.3.2 Le machine learning automatisé : AutoML . . . 9
1.4 Contexte du stage : sélection automatique des variables . . . 10

2 Importance de la sélection de variables en Machine Learning **11**
2.1 La sélection de variables ou Feature Selection . . . 11
2.1.1 Définition . . . 11
2.1.2 Algorithmes de Feature Selection . . . 11
2.2 Mesure de l'importance de variables :Explainable AI . . . 12
2.2.1 Définition . . . 12
2.2.2 Les méthodes de Feature Importance . . . 12
2.3 Valeurs Shapley et Shap importance (SHAP) . . . 15
2.3.1 Formalisation mathématique des Shapley Values . . . 16
2.3.2 Application des Shapley Values en Machine Learning . . . 17

3 Applications théoriques de l'algorithme SHAP : expériences jumelles **18**
3.1 Expériences jumelles . . . 18
3.2 Applications de SHAP aux expériences jumelles . . . 19
3.2.1 Présentation des données d'entrées : Input Space . . . 19
3.2.2 Présentation des données de sorties : Ouput Space . . . 19
3.2.3 Inspection visuelle des résultats . . . 19
3.2.4 Interprétation des résultats . . . 21
3.3 Applications de SHAP aux expériences jumelles avec un bruit gaussien . . . 22
3.3.1 Inspection visuelle des Shapley Values avec 10% de bruit gaussien . . . 22
3.3.2 Inspection visuelle des Shapley Values avec 50% de bruit gaussien . . . 24
3.3.3 Inspection visuelle des Shapley Values avec 100% de bruit gaussien . . . 26
3.3.4 Interprétation des résultats . . . 26

4 Applications industrielles de l'algorithme SHAP sur des données réelles **28**
4.1 Description du jeu de données réelles . . . 28
4.1.1 Présentation des données d'entrées : Input Space . . . 28
4.1.2 Présentation des données de sorties : Ouput Space . . . 28
4.1.3 Présentation des résultats . . . 29
4.1.4 Interprétation des résultats . . . 30
4.2 Application de SHAP sur des données réelles avec des variables fakes . . . 31
4.3 Uniformisation des Valeurs Shapley par les techniques de Feature Scaling . . . 33
4.3.1 Inspection visuelle des résultats . . . 34
4.3.2 Interprétation des résultats . . . 36

4.4 Réduction des effets dissipatifs de SHAP 36

5 Conclusion **39**

Liste des figures

1 Interface site web InFLOWS `https://inflows-ai.com/apropos.html` 7
2 Schéma de la méthodologie des plans d'expériences 9
3 Différents processus de l'AutoML 10
4 synthèse des techniques de Feature Selection 12
5 Schéma explicitant le fonctionnement de SHAP 15
6 Synthèse et interprétation des propriétés vérifiées par les valeurs de Shapley 16
7 Visualisation des différentes fonctions jumelles 18
8 présentation du dataset :Input Space 19
9 présentation du dataset :Output Space 19
10 *Linear* 20
11 *Quadratic* 20
12 *Cubic* 20
13 *Quartic* 20
14 *Quintic* 20
15 *Multilinear* 20
16 *Logarithmic* 21
17 *Exponential* 21
18 *Sinus* 21
19 *Linear* 22
20 *Quadratic* 22
21 *Cubic* 23
22 *Quartic* 23
23 *Quintic* 23
24 *Multilinear* 23
25 *Logarithmic* 23
26 *Exponential* 23
27 *Sinus* 24
28 *Linear* 24
29 *Quadratic* 24
30 *Cubic* 24
31 *Quartic* 24
32 *Quintic* 25
33 *Multilinear* 25
34 *Logarithmic* 25
35 *Exponential* 25
36 *Sinus* 25
37 *Linear* 26
38 *Quadratic* 26
39 *Cubic* 26
40 *Quartic* 26
41 *Quintic* 27
42 *Multilinear* 27
43 *Logarithmic* 27
44 *Exponential* 27

45 *Sinus* 27
46 Présentation du dataset :Input Space 28
47 Présentation du dataset :Output Space 28
48 *Cost* 29
49 *Visco* 29
50 *Ph* 29
51 *Rheo* 29
52 *Stability* 29
53 *Texture* 29
54 *Senso1* 30
55 *Naturality* 30
56 *Microbio30days* 30
57 Résumé des features importances avec SHAP 31
58 Input Space avec ajout des variables fakes 31
59 Inspection visuelle des Shapley Values 32
60 Résultats obtenus grâce à la méthode "filter" 33
61 *Cost* 34
62 *Visco* 34
63 *Ph* 35
64 *Rheo* 35
65 *Stability* 35
66 *Texture* 35
67 *Senso1* 35
68 *Naturality* 35
69 *Microbio30days* 35
70 Présentation visuelle des résultats après la première application de SHAP 36
71 Présentation visuelle des résultats après la deuxième application de SHAP 37
72 Présentation de la matrice des Shapley Values avec les données réelles 38

Résumé

La formulation chimique est une opération industrielle consistant à mélanger différentes matières premières pour concevoir des produits homogènes, stables, possédant des propriétés spécifiques (texture, couleur, odeur, goût, prix...) pour répondre à un cahier de charges précis.
Concevoir un gâteau alimentaire, un yaourt laitier, une crème solaire pour la peau, un shampoing pour les cheveux, du bitume pour les routes, un béton armé sont autant d'exemples de formulation. Formuler de nouveaux produits plus rapidement, plus compétitifs et plus écologiques dans les laboratoires de R&D reste un défi majeur pour les ingénieurs.
Les méthodes in **silico** ou dites "assistée par ordinateur" représentent un outil clé pour s'affranchir des longs mois d'expérimentation essai-erreur en laboratoire.
L'adoption des méthodes d'Intelligence Artificielle en particulier Machine Learning (ML et AutoML) au sein des logiciels permettent de relever ce défi majeur grâce à l'utilisation d'algorithmes qui permettent rapidement de représenter des processus complexes. Ces modèles ne nécessitent pas une spécification explicite des équations mécanistiques régissant le phénomène approché mais se base plutôt sur un apprentissage statistique basé sur un échantillon de données expérimentales.
Une étape importante dans l'apprentissage automatique est la sélection de variables explicatives.
L'objectif de ce travail est d'étudier une nouvelle méthode automatique de sélection de variables SHAP dans les procédés de formulation chimique.
Cet algorithme d'intelligibilité issue de la théorie du jeu coopératif, a été implémenté dans une chaîne de traitement d'AutoML en vue d'améliorer la qualité des simulations et l'optimisation des résultats.

Remerciements

Avant d'aller plus loin dans ce rapport, il m'est très agréable d'exprimer ma reconnaissance envers les personnes qui m'ont apporté leur soutien que ce soit technique et moral dans l'élaboration de ce travail.
Je présente mes profonds respect et reconnaissance au **Ph.D Abdou Kane** CEO d'InFLOWS AI de m'avoir permis de travailler sur un sujet aussi passionnant, pour son enseignement et le temps qu'il m'a consacré. Je tiens également à ajouter que chacune de nos réunions était pour moi un réel plaisir, et ne faisait que m'encourager à approfondir mes connaissances en Intelligence Artificielle.

Mes sincères remerciements vont également aux professeurs **Pierre Dossantos-Uzarralde** et **Baidy Thiongane** les deux responsables de la formation Mastère HPC/Big-Data/IA en co-tutelle entre l'UVS et l'ENSIIE de Paris-Evry pour leurs enseignements, leurs conseils et toute l'énergie qu'ils ont consacré à cette formation.

Un merci très spécial aux enseignants **Mathilde Mougeot**, **Fabrice Mourlain**, **Alain Faye**, **Nestor Demeure**, **Khalifa Sylla**, **Stéphane Genaud** des personnes qui m'ont transmis leur savoir au cours de la formation. J'estime leur travail au plus haut point.
Un très grand merci ainsi que mes sincères salutations à mes camarades de promotions pour le partage et le travail d'équipe.

Je ne saurai conclure cette partie sans une pensée envers ma famille et mes amis, qui, à travers leur soutien omniprésent me permettent d'aller de l'avant et faire du mieux.

1 Introduction générale

1.1 Présentation d'InFLOWS AI : Intelligent Process Flows

InFLOWS AI est une start-up qui développe des logiciels et des boîtes à outils de formulation assistés par ordinateur destinées à formuler des produits chimiques, permettant aux laboratoires de R&D de concevoir des produits chimiques plus rapidement, plus intelligemment et plus écologiques. L'un des principaux défis auxquels les entreprises chimiques sont confrontées est de concevoir le meilleur produit dans un délai défini au bon coût avec une empreinte écologique minimale. La conception de recettes chimiques qui répondent aux exigences de l'entreprise nécessite généralement des essais de conjecture et de vérification afin d'obtenir les bonnes concentrations et les bons paramètres de procédés. Ce voyage de R&D est un exercice d'équilibriste très chronophage et très coûteux en matière première.
Pour répondre à ces défis, les logiciels d'InFLOWS AI intègrent des algorithmes d'Intelligence Artificielle (AI) avancés et des interfaces de visualisation ergonomiques afin de donner une certaine autonomie aux chimistes dans l'exploration de l'espace de formation des produits.

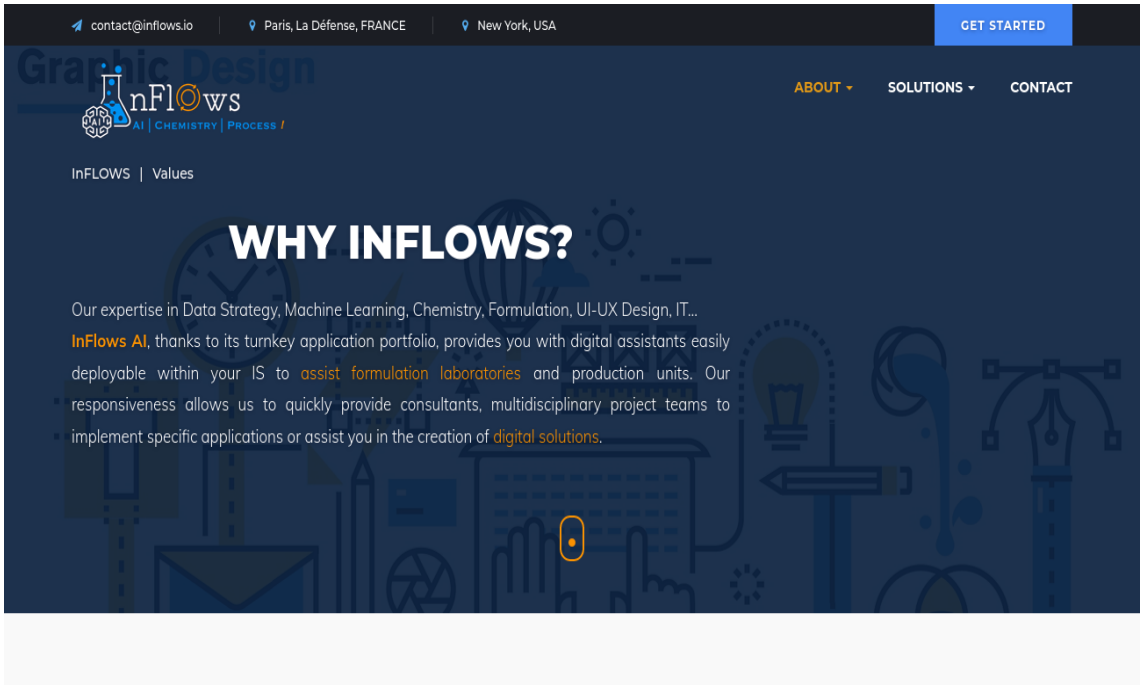

FIGURE 1 – Interface site web InFLOWS `https://inflows-ai.com/apropos.html`

1.2 Problématique industrielle de la Chimie de Formulation

1.2.1 Définition de la chimie de formulation

La formulation est une branche de la chimie consistant à fabriquer des produits homogènes, stables et possédant des propriétés spécifiques, en mélangeant différentes matières premières suivant un cahier de charge qui vise à répondre aux attentes de l'utilisateur, à la réglementation en vigueur, aux contraintes techniques de fabrication...etc.
Cette activité concerne notamment les produits cosmétiques, les produits pharmaceutiques, les parfums, les peintures, les matières plastiques, les produits phytosanitaires, les produits d'entretien, les produits de nettoyage, les adhésifs, les explosifs, les produits agroalimentaires...etc
La formulation dans les industries chimique et para-chimique comprend l'ensemble des savoirs et savoir-faire nécessaires au développement d'un produit commercial. Les personnels des industries chargés de formuler des produits pour un usage particulier sont appelés des formulateurs. La formulation est aujourd'hui une des branches les plus importantes de la chimie.

1.2.2 Problèmes de la chimie de formulation

Les industries des cosmétiques, de l'alimentation, de la nutrition, de la pharmaceutique, de la chimie et des matériaux sont confrontées à des difficultés récurrentes lors des phases de conception des produits. Le défi : innover / concevoir des produits performants, compétitifs, stables, éco-durables, dans des délais courts : Time to Product.
A cela s'ajoutent des aspects tels que la traçabilité des processus, la gestion de la collaboration, l'historisation des connaissances, la maîtrise des coûts de R&D. A titre d'exemples, on peut citer l'intégration d'un nouvel actif innovant dans une formule, la mise au point d'une recette alimentaire en minimisant le taux de conservateurs, le remplacement d'une matière première soumise à la réglementation, la mise en place d'un procédé industriel à moindre empreinte énergétique.
Techniciens, formulateurs, ingénieurs, scientifiques s'efforcent de repousser les limites de l'innovation en expérimentant des procédés, des réglages et des mélanges de matières. L'approche intuitive consiste à partir d'une "première hypothèse", c'est-à-dire d'un procédé/formule s'approchant de la cible, puis par un ensemble d'incréments progressifs d'entrées, à naviguer visuellement pour tenter d'atteindre les performances attendues. Ce processus est fastidieux, car pour une formule comprenant 10 paramètres prenant chacun 10 valeurs, il existe 10 milliards de combinaisons. Ce qui est rédhibitoire pour des expériences physiques.
En général, l'expertise, les contraintes opérationnelles, le savoir-faire métier permettent d'éviter certaines combinaisons improbables pour réduire l'espace des possibles à quelques centaines voire milliers de configurations. Mais il reste tout de même élevé. De plus, l'exploration n'étant pas planifiée, il devient difficile de tirer les leçons des relations de cause à effet. au sein du processus, de capitaliser les tests effectués. Cela peut conduire à refaire les mêmes expériences pour un besoin légèrement différent.
Les modèles mathématiques peuvent être utilisés par le biais de la simulation numérique et donc de la virtualisation des expériences. Cependant, cela suppose que le modèle sous-jacent reliant les entrées aux sorties soit connu, ce qui nécessite des années de recherche pour l'établir et le mettre en œuvre. Ce modèle devient caduc dès qu'un nouveau composant est ajouté ou supprimé. Ce qui n'est pas pratique pour une industrie qui se veut agile.

1.3 Méthodes statistiques et d'apprentissages statistiques

1.3.1 Plans d'expériences

Les statisticiens ont inventé la méthodologie des plans d'expériences (Fisher 1935). En résumé, elle consiste à planifier un ensemble limité d'expériences destinées à sillonner le champ de recherche, puis à établir avec ces expériences un modèle simplifié de la relation de cause à effet (linéaire, quadratique, interactions de premier ordre...). L'inférence sur l'objectif est faite en exploitant les coefficients des régressions, et les prédictions. Cette méthodologie a montré son efficacité dans divers domaines par le passé.

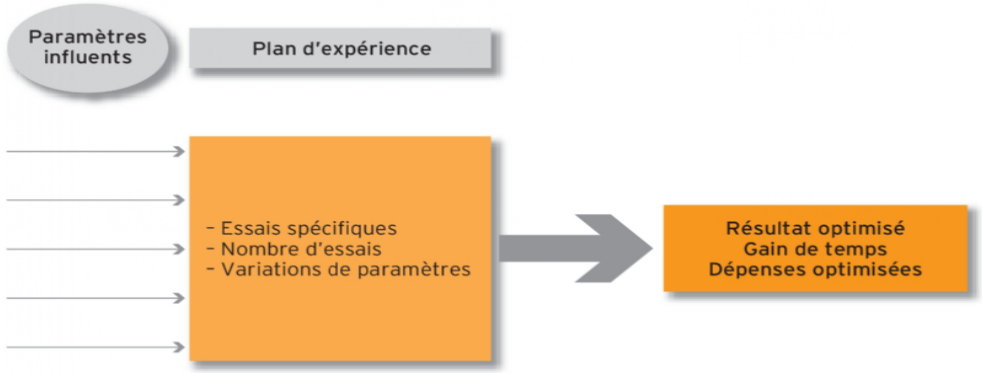

FIGURE 2 – Schéma de la méthodologie des plans d'expériences

Cependant, il y a deux inconvénients à ne pas oublier :

— il faut avoir une formation statistique pour les mettre en œuvre.

— la complexité actuelle des formules et des procédures ne peut plus être expliquée simplement par les hypothèses trop simples des plans d'expérience classiques.

En chimie, par exemple, nous aurons des transitions de phase, des ruptures de phénomène. Un exemple quotidien est l'évolution de la température d'un bloc de glace soumis à une source de chaleur. On observe des niveaux de température lors des changements d'état, et des variations quasi linéaires, pour les phases homogènes, laissant place à un modèle en escalier.

1.3.2 Le machine learning automatisé : AutoML

Le machine learning

Le machine learning également appelé apprentissage statistique est une technique de programmation informatique qui utilise les probabilités et statistiques pour permettre aux ordinateurs d'apprendre d'eux-même, l'objectif étant d'apprendre aux ordinateurs d'agir sans être explicitement programmés en utilisant des programmes de développement qui s'ajustent chaque fois qu'ils sont exposés à différentes types de données en entrée.

Le machine learning automatisé :AutoML

Le Machine Learning automatisé, également appelé ML automatisé ou AutoML est le processus d'automatisation des tâches fastidieuses et itératives de développement de modèle de Machine Learning.

Le Machine Learning Automatisé, ou AutoML, rend le Machine Learning (ML) accessible aux non-experts en leur permettant de créer, de valider, d'itérer et d'explorer des modèles ML dans un contexte d'automatisation. L'autoML prépare et nettoie automatiquement les données, crée et sélectionne des caractéristiques, choisit la famille de modèles appropriée, optimise les hyperparamétres et analyse les résultats. Il facilite également la visualisation des données, la génération d'insights, l'explicabilité et le déploiement des modèles.
L'autoML est un pipeline complet comprenant le data pré-processing, le feature engineering, le feature selection ainsi que le choix du modèle et l'optimisation de ces hyperparamètres.

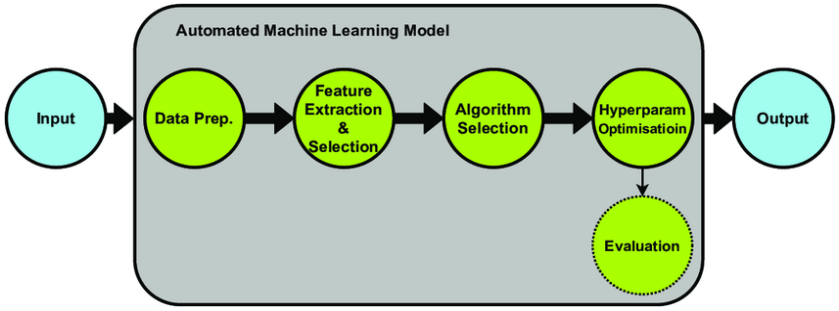

FIGURE 3 – Différents processus de l'AutoML

1.4 Contexte du stage : sélection automatique des variables

Ce stage intervient dans la cadre d'un projet de R&D au sein d'InFLOWS AI qui vise à développer une nouvelle approche de sélection des variables au cours des processus d'AutoML, basée sur un algorithme d'intelligibilité : Shapley Additive exPlanations ou SHAP. Une méthode qui permet de mesurer l'importance des variables à partir de la théorie des jeux coopératifs appliquée en Machine Learning.
En effet, lors de la conception d'un nouveau produit par exemple un produit cosmétique, les algorithmes d'AutoML intégrés dans les logiciels de formulation assistés par ordinateur sont confrontés à des problèmes de sélection des variables qui influencent la qualité de la prédiction et l'optimisation des résultats.
La mission de ce stage est une mission de Data Scientist qui consiste à étudier l'applicabilité de cette nouvelle approche de sélection de variable à partir de la mesure d'importance de l'algorithme SHAP. Pour permettre aux formulateurs et aux chimistes de concevoir facilement des nouveaux produit plus stables, plus performants et plus écologiques dans un délai court.
C'est ainsi pour bien mener la mission et comprendre la problématique du stage, une analyse bibliographique des méthodes de sélection des variables et des algorithmes de mesures d'importance des variables en Machine Learning est abordée en premier lieu.
Ensuite un travail de validation de la méthode SHAP est effectué par la méthodologie des expériences jumelles. Suivi d'une application réelle de la méthode SHAP sur des données issues de l'industrie cosmétique.

2 Importance de la sélection de variables en Machine Learning

En Machine Learning (ML), il existe deux concepts fondamentaux : la sélection de variables (ou feature selection en Anglais) et la mesure de l'importance de variables (ou feature importance en Anglais)

2.1 La sélection de variables ou Feature Selection

2.1.1 Définition

La sélection de variables (ou Feature Selection en Anglais) est le processus de réduction du nombre de variables d'entrée dans les projets d'apprentissage automatique (AutoML). Après tout, ces variables de caractéristiques sont les paramètres qui construisent un modèle prédictif ou un classifieur. En effet lors de la création d'un modèle d'apprentissage automatique dans la vie réelle, il est presque rare que toutes les variables de l'ensemble de données soient utiles pour créer un modèle. Car la présence de variables redondantes réduit la capacité de généralisation du modèle et peut également réduire la précision globale d'un classificateur. De plus, ajouter de plus en plus de variables à un modèle augmente la complexité globale du modèle.Ainsi, la sélection de variable devient un élément indispensable de la création de modèles d'apprentissage automatique.
Les principales raisons d'utiliser la Sélection des variables sont :

- Cela permet à l'algorithme d'apprentissage automatique de s'entraîner plus rapidement.
- Elle réduit la complexité d'un modèle et le rend plus facile à interpréter.
- Cela améliore la précision d'un modèle si le bon sous-ensemble est choisi.
- Elle réduit le surajustement.

2.1.2 Algorithmes de Feature Selection

Les algorithmes de Feature Selection sont catégorisés en deux groupes :

Supervisées

Il existes trois types de méthodes de Feature Selection dans l'approche supervisées :

- Filter methods : ANOVA, LDA, Pearson correlation, variance thresholding,Khi-Square...etc
- Wrapper methods : forward, backward, and stepwise selection.
- Embedded methods : Lasso, Ridge, Decision Tree, RandomForest...etc

Non supervisées

La sélection de variable en mode non-supervisé est un vrai challenge en Machine Learning en raison du manque d'informations sur les labels des données. Cependant dans la pratique, elle consiste soit à supprimer les variables redondantes statistiquement (corrélation) ou bien à réduire la dimensionnalité (ACP,ACI,SVM) dans le but d'obtenir les fonctionnalités qui expliquent le plus l'ensemble de données.

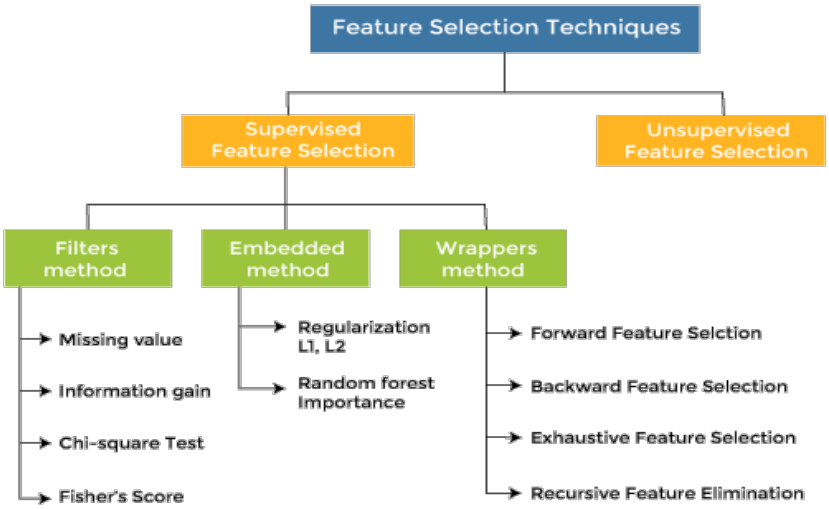

FIGURE 4 – synthèse des techniques de Feature Selection

2.2 Mesure de l'importance de variables :Explainable AI

2.2.1 Définition

Lorsque nous adaptons un modèle d'apprentissage automatique supervisé ou un AutoML, nous souhaitons souvent comprendre quelles fonctionnalités (ou variables) sont les plus associées au résultat qui nous intéresse. Les caractéristiques (ou variables) fortement associées aux résultats sont considérées comme plus « importantes ».
La Feature Importance (FI) consiste à estimer de manière objective l'utilité d'une caractéristique ou variable. Cette démarche peut s'avérer utile pour sélectionner les variables explicatives dans un modèle d'AutoML. Chacune d'entre elles reçoit un score (ou un poids), et elles peuvent ainsi être classées en fonction de leurs scores. Celles avec le plus haut score peuvent être choisies pour être incluses dans l'ensemble des données.
Il existe de nombreuses raisons pour lesquelles, le calcul de l'importance des variables dans le cadre d'un flux de travail d'apprentissage automatique est fortement recommandé :

— la Feature Importance est souvent utilisée pour la Feature Selection ou pour la réduction de la dimensionnalité. Comme par exemple Filter methods et Wrapper methods l' utilisent pour supprimer les fonctionnalités non pertinentes dans le but d'augmenter l'efficacité d'un modèle de Machine Learning ou un AutoML.
— la Feature Importance peut également être utilisée pour l'inspection et l'interprétabilité d'un modèle de Machine Learning ou AutoML :l'eXplainable AI.

2.2.2 Les méthodes de Feature Importance

Il existe trois catégories de méthodes de calculs d'importance des variables en Machine Learning :

— À partir des coefficients : c'est une façon simple de calculer l'importance des variables en examinant les coefficients du modèle. Par exemple, la régression linéaire (Lasso et Ridge) et logistique.

— À partir d'un Arbre de décision (tree-based model) :C'est l'un des moyens les plus rapides d'obtenir l'importance des variables. Par exemple, Random Forest, Xgboost, SHAP (Tree-SHAP).
— À partir d'une réduction de dimensionnalité : On peut également obtenir l'importance des variables après une réduction de la dimensionnalité.
Par exemple ACP, LDA, KernelACP, KernelSVM...etc.

En machine Learning, il existe ainsi un compromis entre la performance d'un modèle et son interprétabilité : ce qu'un modèle gagne en performance, il peut le perd en interprétabilité (et inversement).

Le tableau ci dessous permet de faire une synthèse des méthodes de Feature importance les plus utilisées en Machine Learning dans le cas d'une Classification ou d'une Régression.

Algorithmes	**Avantages**	**Inconvénients**
Xgboost : eXtreme Gradient Boosting	— Très flexible. — Plus rapide que Gradient Boosting. — Prend en charge la régularisation. — Traitement en parallèle. — Rapide, précis et efficace	— Difficulté sur des données données clairsemées et non structurées. — Effet Black Box et probléme d'interprétabilité du modéle. — Un panel d'hyperparamètres très important. — Risque d'Overfitting
Random Forest	— Fonctionne bien avec tout type de donnée. — Pas d'influence avec les données aberrantes. — Offre une grande précision et équilibre bien le compromis biais-variance.	— Effet Black Box et problème d'interprétabilité du modèle. — Nécessite beaucoup de ressources informatiques.

Algorithmes	Avantages	Inconvénients
SHAP : SHapley Additive exPlanations	— Base théorique solide. — Existance de deux méthodes d'estimation :KernelSHAP (méthode inspirée de LIME) et TreeSHAP (méthode à base d'arbres de décision). — Modèle d'interprétation globales ayant une bonne cohérence avec les explications locales. — Une implémentation rapide pour les modèles arborescents. — Relie les valeurs LIME et Shapley même temps.	— Possibilité de créer intentionnellement des interprétations trompeuses. — KernelSHAP est lent. — KernelSHAP ignore la dépendance aux fonctionnalités. — TreeSHAP peut produire des attributions de fonctionnalités peu intuitives.
LIME : Local Interpretable Model-agnosticExplanations	— Modèle local, Interprétable et agnostique,capable d'expliquer n'importe quel modèle de machine learning. — Flexibilité quant aux features utilisées. — Requiert l'entraînement d'un modèle pour chaque instance à expliquer.	— Biais dû à une hypothèse de non-corrélation entre features. — Les résultats peuvent varier dépendant de l'échantillonnage. — Fonctionnement local qui ne permet pas de généraliser. l'interprétabilité à un niveau global. — la méthode est utilisable pour des données textuelles ou sur des images.
Feature Permutation	— Simple à interpréter. — Donne des explications globales, sur un ensemble de données. — Alerte sur les variables peu utilisées ou très corrélées lorsque les valeurs d'importances sont très faibles. — Pas besoin d'entraîner un modèle.	— Les résultats peuvent varier énormément, car la permutation est aléatoire. — Biais dû à une hypothèse de non-corrélation entre features. — Le calcul se fait sur l'ensemble des données. — Nécessité de connaître la vraie sortie.

En analysant ce tableau, il faut remarquer que l'algorithme SHAP est l'algorithme le plus utilisé en Machine Learning surtout en Feature Engineering grâce à son :

— **Explicabilité** :
Donne des informations sur le « raisonnement » de l'algorithme de Machine Learning et sur les données qu'il a utilisées. Ces informations sont destinées prioritairement aux experts de l'IA, car elles nécessitent une compréhension des éléments techniques du modèle et de l'analyse des données.

— **Interprétabilité** :
Pour sa part a pour rôle de fournir l'information dans un format compréhensible par tous. Il s'agit souvent de « traduire » les explications en éléments « interprétables » par une personne travaillant dans le domaine considéré mais sans connaissances spécifiques en IA.

2.3 Valeurs Shapley et Shap importance (SHAP)

C'est une méthode d'estimation des valeurs de Shapley (théorie des jeux coopératifs), présentée par Scott M. Lundberg en 2017, ou plutôt plusieurs méthodes d'estimation, telles KernelSHAP qui est inspirée de LIME , et TreeSHAP qui est destinée aux modèles basés sur les Arbres de décision.
Pour une instance donnée, la valeur de Shapley d'une feature (ou d'un groupe de features) est sa contribution à la différence entre la valeur prédite par le modèle et la moyenne des prédictions de celui-ci.
Pour calculer les valeurs de Shapley de features pour une instance, on simule différentes combinaisons de valeurs de features, sachant qu'on peut avoir des combinaisons où une feature est totalement absente. Pour chaque combinaison, on calcule la différence entre la valeur prédite et l'espérance, c'est à dire la moyenne des prédictions sur les données réelles.
La valeur de Shapley d'une feature est alors la moyenne de la contribution de sa valeur à travers les différentes combinaisons.

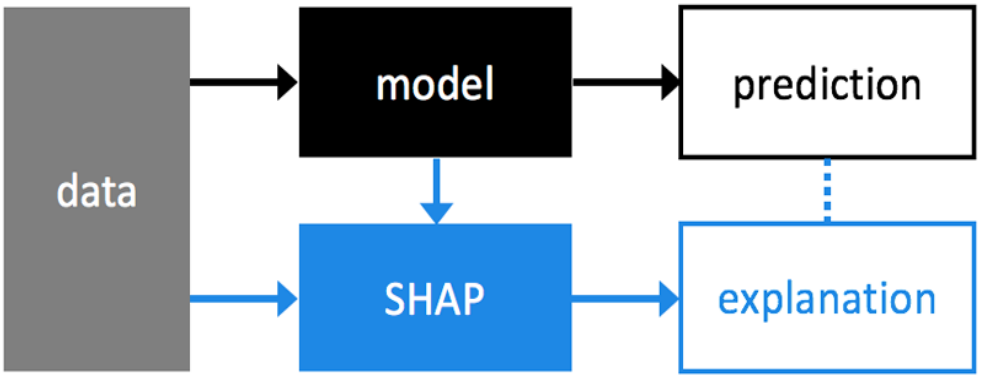

FIGURE 5 – Schéma explicitant le fonctionnement de SHAP

2.3.1 Formalisation mathématique des Shapley Values

Soit un jeu coopératif disposant de n joueurs et d'une fonction caractéristique du jeu c, indiquant pour chaque coalition de joueur (sous-ensemble de joueurs) le gain maximal qu'ils peuvent obtenir en collaborant définie par :

$$c : \mathbb{P}(N) \mapsto \mathbb{R} \text{ tel que } N = \{1, ..., n\}$$

Le gain total $\mathbb{G}$ est le gain $c(N)$ qu'obtiennent tous les joueurs lorsqu'ils collaborent ensemble.
Le théorème de Shapley nous dit qu'il existe une unique fonction :

$$\phi : \begin{cases} N \mapsto \mathbb{R} \\ i \mapsto \phi_i(c) \end{cases}$$

Satisfaisant les quatre propriétés suivantes, qui permettent de montrer que la répartition du gain entre les joueurs est équitable.

Propriété	Théorie	Interprétation	Exemple
Efficience	$\sum_{i \in N} \phi_i(c) = c(N) - c(\emptyset)$	La **somme** des parts de chaque joueur doit **être égale au gain total.** En général c(∅) = 0, mais ce n'est pas toujours le cas, en particulier en intelligibilité !	Le trésor (gain) est partagé en intégralité entre les n pirates (joueurs)
Symétrie	$\forall Z\ c(Z \cup \{i\}) = c(Z \cup \{j\}) \implies \phi_i(c) = \phi_j(c)$	Si **deux joueurs contribuent de la même façon** dans toutes les coalitions dans lesquelles ils apparaissent, **leurs parts doivent être égales.**	Deux pirates qui contribuent de la même façon dans l'obtention du trésor, obtiennent la même part du butin.
Joueur nul	$\forall Z\ c(Z \cup \{i\}) = c(Z) \implies \phi_i = 0$	Si toutes les coalitions dans lesquelles un **joueur est présent ont le même gain avec et sans lui, alors la part de ce joueur est nulle**	Un pirate qui n'apporte rien, quel que soit le groupe de pirates avec lequel il collabore, n'obtient rien.
Additivité	$\phi_i(c_1 + c_2) = \phi_i(c_1) + \phi_i(c_2)$ $\phi_i(ac_1) = a\phi_i(c_1)$	**Additivité** des indices de Shapley par rapport à la **fonction caractéristique du jeu**	Si le groupe de n pirates obtient deux trésors, l'un après l'autre, les partager successivement, revient au même que de distribuer simultanément les deux trésors aux n pirates

FIGURE 6 – Synthèse et interprétation des propriétés vérifiées par les valeurs de Shapley

Cette fonction est calculée par la formule suivante :

$$\phi_i(c) = \sum_{Z \subseteq N \setminus \{i\}} \frac{|Z|!(n - |Z| - 1)!}{n!} \times [c(Z \cup \{i\}) - c(Z)]$$

Pour obtenir ϕ_i il faut donc calculer pour chaque coalition Z dans laquelle le joueur i n'apparaît pas la différence de gain $c(Z \cup \{i\}) - c(Z)$. Cela permet de comparer le gain obtenu de la coalition avec et sans ce joueur, afin de mesurer son impact lorsqu'il collabore avec cet ensemble de joueurs.

Si cette différence est positive, cela signifie que le joueur i contribue positivement à cette coalition. A l'inverse, si la différence est négative, cela signifie que le joueur i pénalise le groupe. Enfin, si la différence est nulle, cela indique que le joueur i n'apporte rien à ce groupe.
On calcule ensuite la moyenne de ces écarts sur toutes les coalitions dans lesquelles le joueur i apparaît.

2.3.2 Application des Shapley Values en Machine Learning

Pour passer de la théorie des jeux au Machine Learning, les joueurs deviennent les modalités des variables explicatives. Le gain à répartir devient la différence entre prévision et moyenne des prévisions.
En Machine Learning, on souhaite expliquer la prédiction $f(x)$ associée à une observation x. A chaque couple observation-prédiction $(x, f(x))$, est associée un jeu :

- Les joueurs sont les valeurs x_i prises par x sur chaque variable d'entrée.
- La quantité à répartir équitablement entre tous ces joueurs est la différence entre la prédiction $f(x)$ et la moyenne des prédictions $\mathbb{E}[f(X)]$.
- La fonction caractéristique du jeu est : $c(u) = \mathbb{E}[f(X)|X_u = x_u]$, définie pour toute coalition u de valeurs x_u de x.
  Si u est la coalition $\{1, 2, 4\}$,première, deuxième et quatrième variables d'entrée, la notation $X_u = x_u$ correspond à l'évènement$X_1 = x_1, X_2 = x_2, X_4 = x_4$

La valeur de Shapley associée à une modalité x_i est donc définie par :

$$\phi_i(f, x) = \sum_{u \subseteq \{1,\ldots,n\} \setminus i} \frac{|u|!(n - |u| - 1)!}{n!} \times [\mathbb{E}[f(X)|X_{u \cup \{i\}} = x_{u \cup \{i\}}] - \mathbb{E}[f(X)|X_u = x_u]]$$

La somme des valeurs de Shapley d'une observation x est égale à l'écart entre la prévision $f(x)$ et la moyenne des prévisions $\mathbf{E}[f(X)]$:

$$f(x) - \mathbb{E}[f(X)] = \sum_{i=1}^{p} \phi_i$$

On insiste sur le fait que ce n'est pas la prévision $f(x)$ elle-même que l'on répartit entre les joueurs (valeurs) x_i, mais la quantité $f(x) - \mathbb{E}[f(X)]$.
Autrement dit, le coefficient ϕ_i explique comment les valeurs x_i contribuent à décaler la prévision $f(x)$ de la moyenne $\mathbb{E}[f(X)]$ des prévisions.

3 Applications théoriques de l'algorithme SHAP : expériences jumelles

3.1 Expériences jumelles

Une expérience jumelle est un moyen de créer un jeu de données simple et dont on connaît à l'avance la solution.
L'idée est la suivante : on prend quelques fonctions mathématiques (Linear,quadratique, cubic,quartic, quintic, multilinear, logarithmic, exponential et sinus), à partir de celles-ci, on calcule le nombre de points voulus de cette fonction : $\mathbb{Y} = f(\mathbb{X})$
On a alors un jeu de données d'entrée et un jeu de données de sortie sur lequel on peut entraîner notre modèle. On peut ensuite l'évaluer en le comparant avec la formule exacte du modèle mathématique qu'il est censé prédire.
Dans notre contexte, il s'agit de tester le rapport **cause** à **effet** de l'algorithme SHAP à travers les Shapley Values lors de la prédiction des variables Jumelles (twin experiment). Pour cela, grâce à une distribution **Random uniform** $\mathbb{X}$(variable antécédente), plusieurs distributions jumelles ont été crées comme le montre la figure ci-dessous (Figure 7).

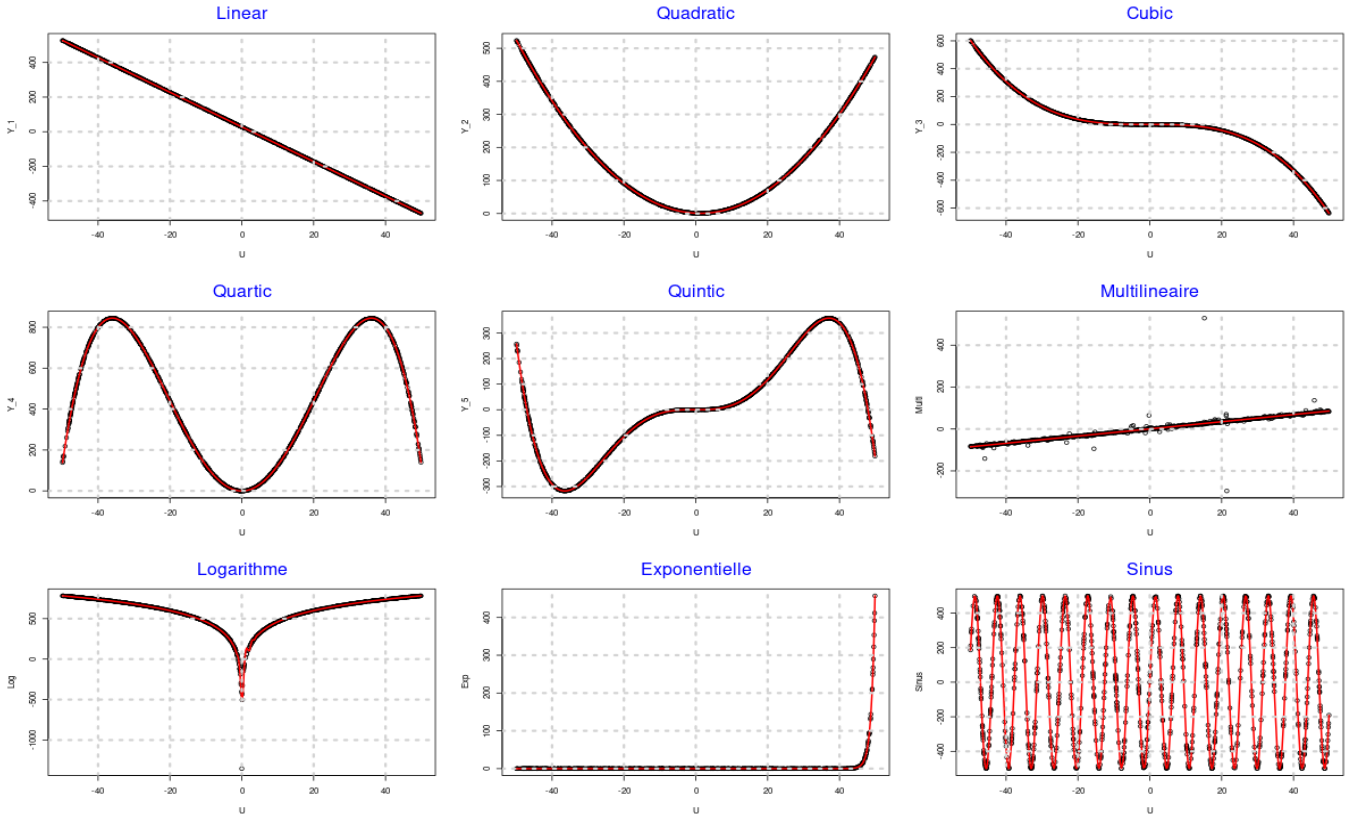

FIGURE 7 – Visualisation des différentes fonctions jumelles

3.2 Applications de SHAP aux expériences jumelles

3.2.1 Présentation des données d'entrées : Input Space

Le dataset Input Space est constitué de la variable explicative (Unif) et des variables parasites (variables fakes en Anglais).

	Unif	Cauchy	Norm	X1	X2	X3	X4	X5	X6
0	-4.873263	-1.059476	0.215982	0.623512	29.243352	-47.002046	-0.435964	-0.219982	-0.142677
1	28.377979	-4.150990	-1.392538	0.397743	71.238839	-28.955793	-3.753248	-5.145785	2.299116
2	20.968223	1.290448	-0.074378	0.884932	10.549968	-77.697173	2.175380	2.101002	-0.084937
3	-11.825574	1.883787	-1.136039	0.543784	70.409794	-2.430393	2.427571	1.291532	-1.163728
4	13.632377	-0.987949	-0.429511	0.209771	21.398702	-79.668361	-0.778179	-1.207690	0.089013
5	20.134602	-0.051985	0.479576	0.681045	94.720501	-31.585792	0.629060	1.108636	-0.016979
6	14.043892	-6.207709	-0.693070	0.249406	57.717718	-77.588326	-5.958304	-6.651373	1.073036
7	-23.332027	1.919717	-0.077139	0.498082	60.477448	-82.794675	2.417799	2.340660	-0.073758
8	31.542154	-2.361598	0.262205	0.785640	27.259275	-93.994396	-1.575958	-1.313753	-0.486487
9	48.298687	-0.215583	1.782135	0.536763	1.322086	-4.615170	0.321180	2.103315	-0.206223

FIGURE 8 – présentation du dataset :Input Space

3.2.2 Présentation des données de sorties : Ouput Space

Ce dataset Output Space contient les variables de réponse (ou jumelles) obtenues grâce aux différentes fonctions mathématiques et qui représentent les variables à prédire par le modèle d'apprentissage automatique Random Forest.

	Linear	Polynom2	Polynom3	Polynom4	Polynom5	Multilinear	Log	Exp	Sinus
0	76.732633	8.186371	0.342075	30.231304	-1.484406	-7.368417	316.752760	1.248728e-19	493.543804
1	-255.779786	147.872945	-119.540557	722.280738	261.191678	50.061044	669.122689	2.110569e-07	-51.729626
2	-181.682230	78.449164	-48.907191	474.553028	132.294141	35.271004	608.601620	1.277567e-10	426.817756
3	146.255741	34.881628	7.129048	171.659264	-24.013077	-21.199785	494.052897	3.210957e-20	337.437942
4	-108.323769	31.352152	-13.797992	223.965642	42.005495	23.797211	522.489524	8.326575e-14	437.638020
5	-173.346025	72.013142	-43.396128	444.487403	119.450459	34.746647	600.487970	5.550687e-11	479.725288
6	-112.438915	33.424232	-15.054492	236.590144	45.617354	27.001242	528.437507	1.256564e-13	497.826501
7	261.320274	121.542714	59.386853	559.161853	-155.113223	-40.355161	629.965396	9.257615e-20	486.842596
8	-287.421536	184.210414	-163.468923	798.099269	312.302780	55.207342	690.264972	4.995549e-06	62.946070
9	-454.986868	443.403286	-579.055442	311.340143	-32.438342	83.228413	775.480874	9.459173e+01	-461.305774

FIGURE 9 – présentation du dataset :Output Space

3.2.3 Inspection visuelle des résultats

Dans cette section, il s'agit de présenter les Features Importances (importance des variables) obtenus avec SHAP et celles du modèle de prédiction (Random Forest) pour chaque variable de réponse ou variable jumelle. Dans la perspective d'une analyse comparative des résultats.

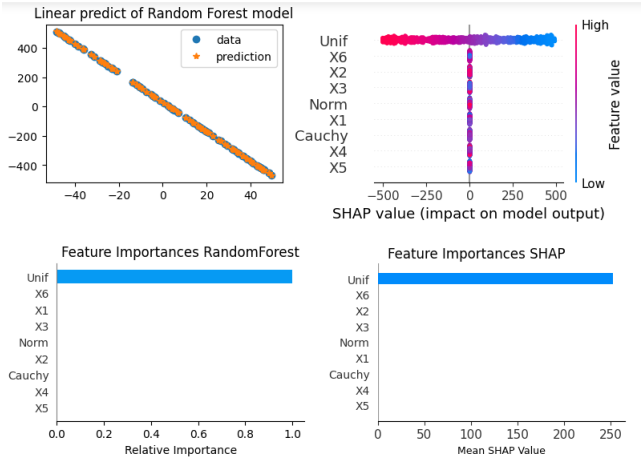

FIGURE 10 – *Linear*

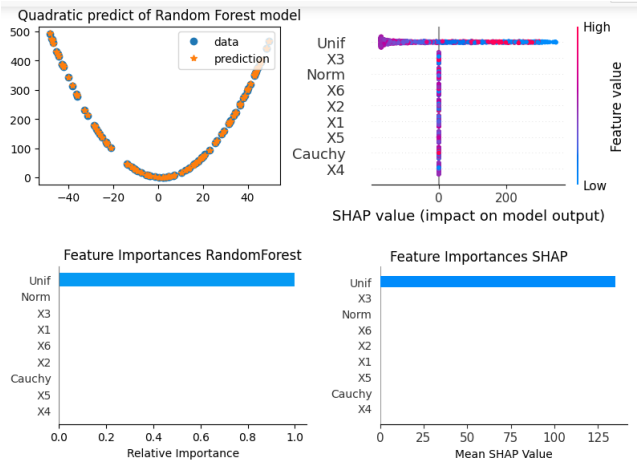

FIGURE 11 – *Quadratic*

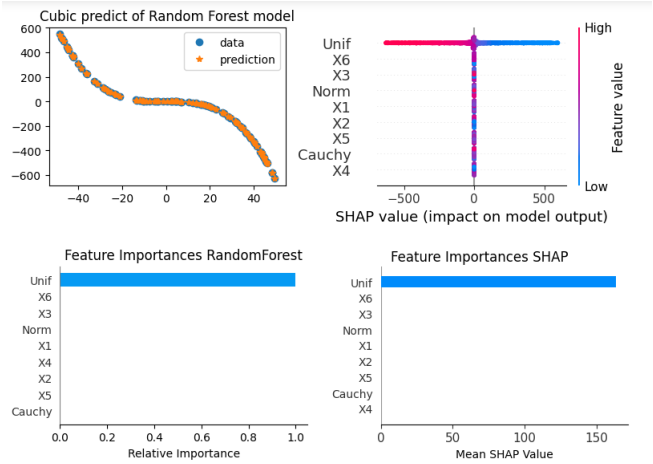

FIGURE 12 – *Cubic*

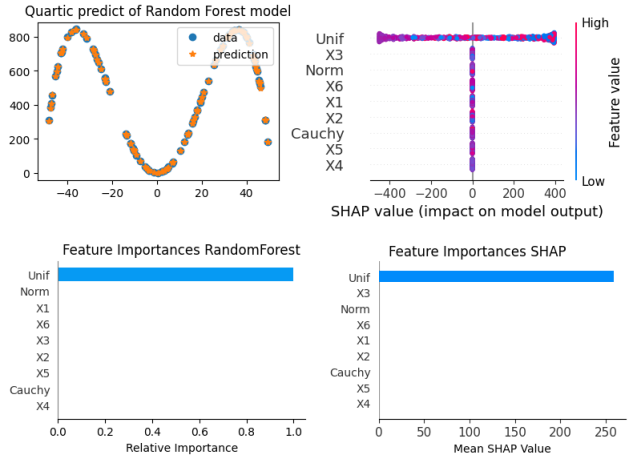

FIGURE 13 – *Quartic*

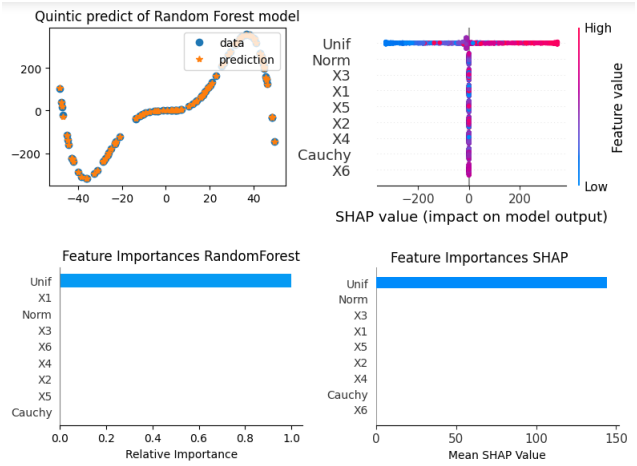

FIGURE 14 – *Quintic*

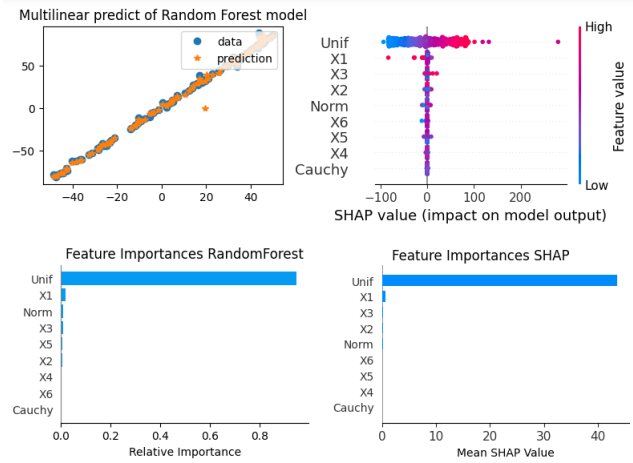

FIGURE 15 – *Multilinear*

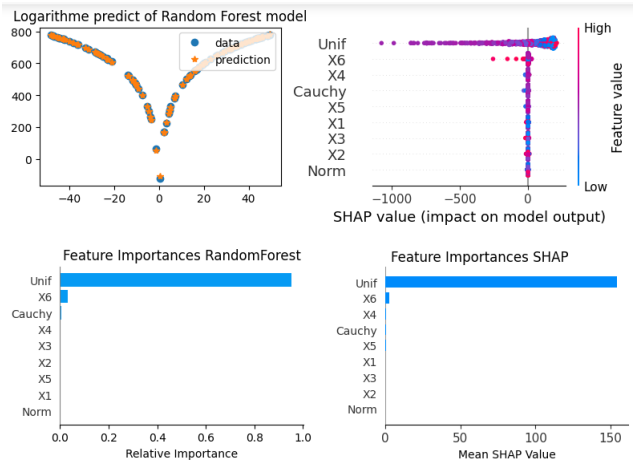

FIGURE 16 – *Logarithmic*

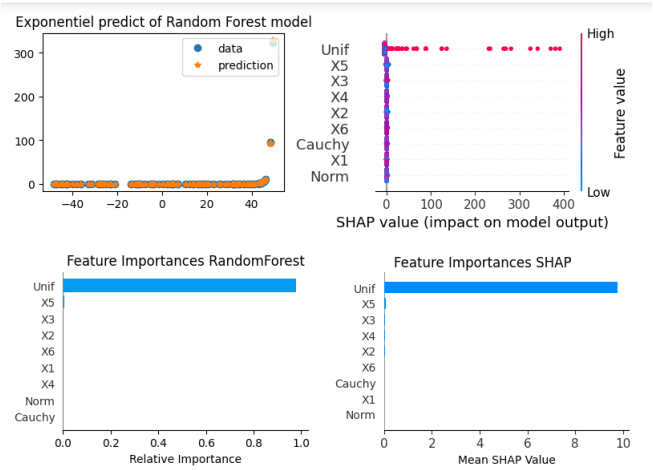

FIGURE 17 – *Exponential*

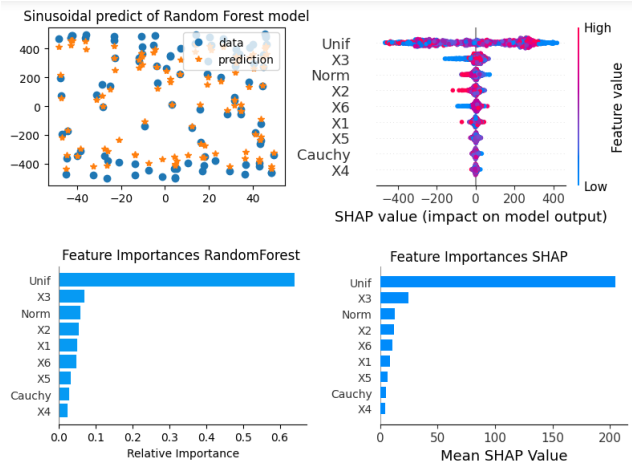

FIGURE 18 – *Sinus*

3.2.4 Interprétation des résultats

L'inspection visuelle de ces différents résultats montre que SHAP tout comme le Random Forest parviennent à bien détecter la variable explicative (Unif) dans les expériences jumelles. Mise à part que pour la variable jumelle Sinus, les deux modèles de Feature Importances sont moins performants à cause de la présence des variables fakes dans les résultats.
Donc on peut conclure que SHAP parvient bien à détecter la variable importante dans un modèle de prédiction. Par contre lorsque la prédiction est sinusoïdale, SHAP ne parvient pas correctement à distinguer les variables fakes (variables fausses en français).

3.3 Applications de SHAP aux expériences jumelles avec un bruit gaussien

Le bruit altère les données et risque de rendre difficile l'apprentissage de la relation que l'on cherche à prédire, voire de rendre la modélisation impossible. Un bruit gaussien est un bruit dont la densité de probabilité est une distribution gaussienne (loi normale).
En supposant que la variable aléatoire à prédire est $\mathbb{Y}$ à partir d'une variable aléatoire $\mathbb{X}$ par la fonction f, alors on a : $\mathbb{Y} = f(\mathbb{X}) + \varepsilon$
tel que ε est une variable aléatoire indépendante de $\mathbb{X}$ qui représente le bruit gaussien dont sa densité de probabilité est une loi gaussienne (ou loi normale) centrée : $p(\mathbb{X}) = \dfrac{1}{\sigma\sqrt{2\pi}}\, e^{(-\frac{\mathbb{X}^2}{2\sigma^2})}$
Dans notre cas, il s'agit de tester, le comportement de SHAP lorsqu'on ajoute un bruit gaussien à des pourcentages différents sur le dataset Input Space.

3.3.1 Inspection visuelle des Shapley Values avec 10% de bruit gaussien

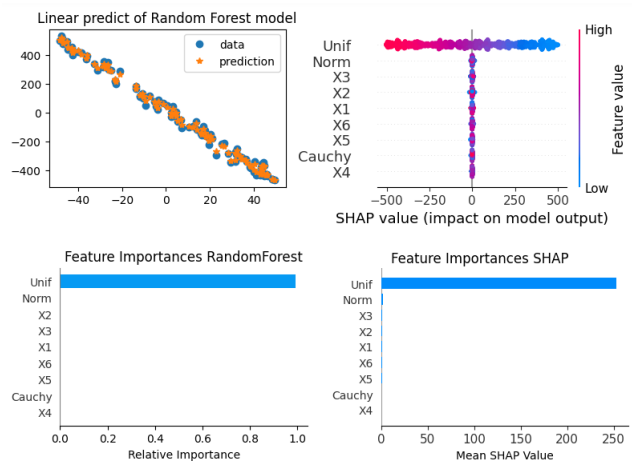

FIGURE 19 – *Linear*

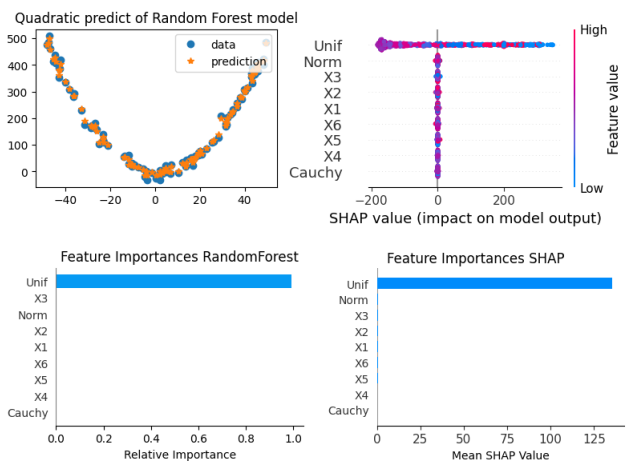

FIGURE 20 – *Quadratic*

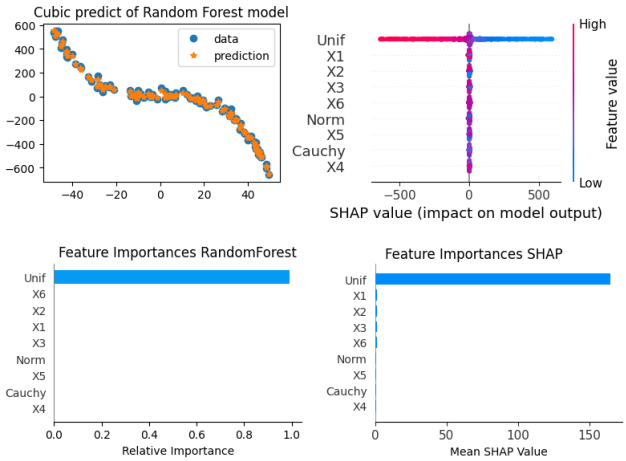

FIGURE 21 – *Cubic*

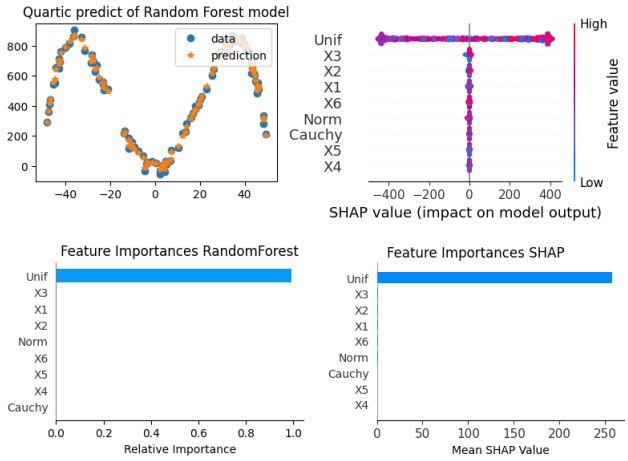

FIGURE 22 – *Quartic*

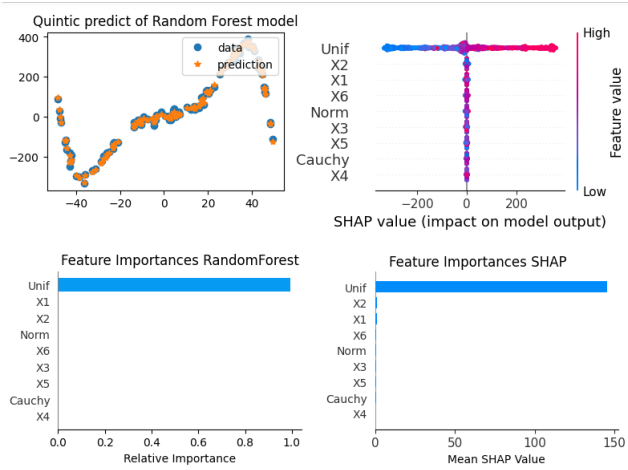

FIGURE 23 – *Quintic*

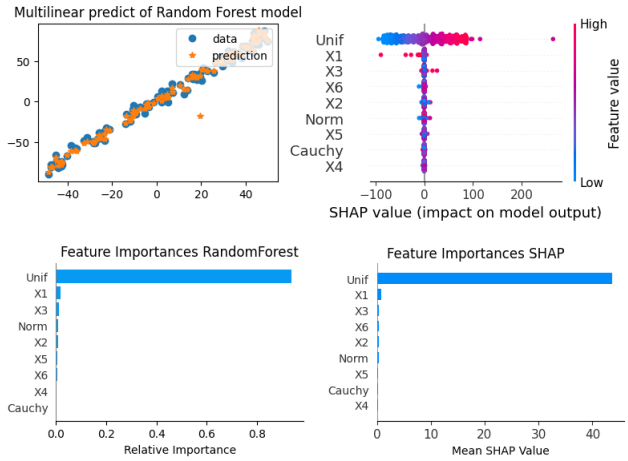

FIGURE 24 – *Multilinear*

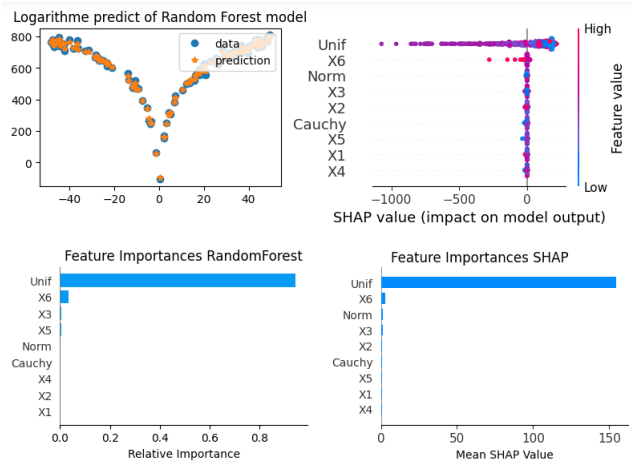

FIGURE 25 – *Logarithmic*

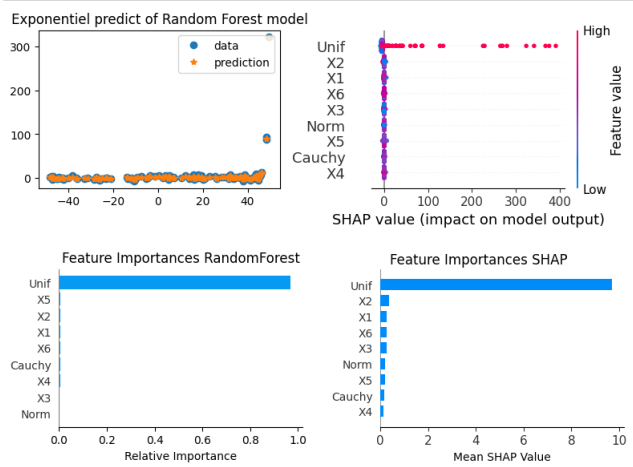

FIGURE 26 – *Exponential*

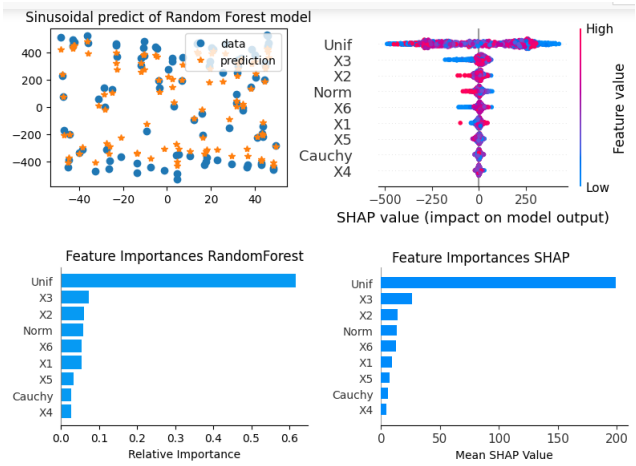

FIGURE 27 – *Sinus*

3.3.2 Inspection visuelle des Shapley Values avec 50% de bruit gaussien

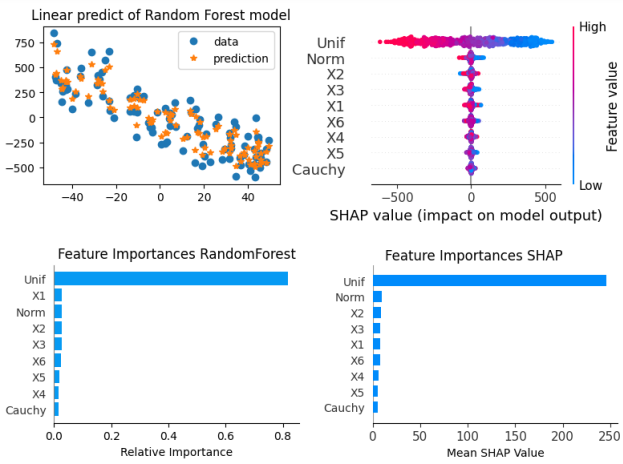

FIGURE 28 – *Linear*

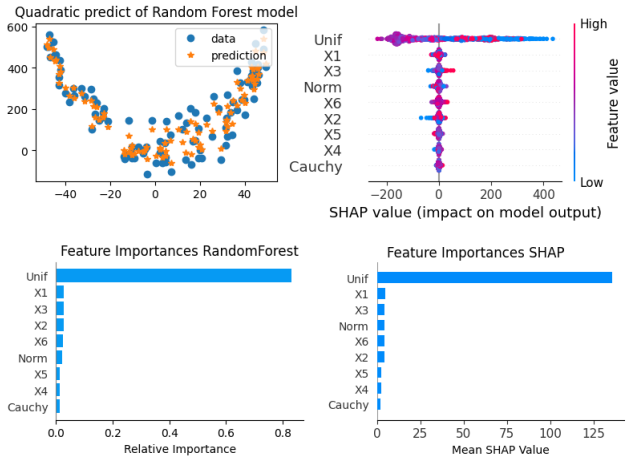

FIGURE 29 – *Quadratic*

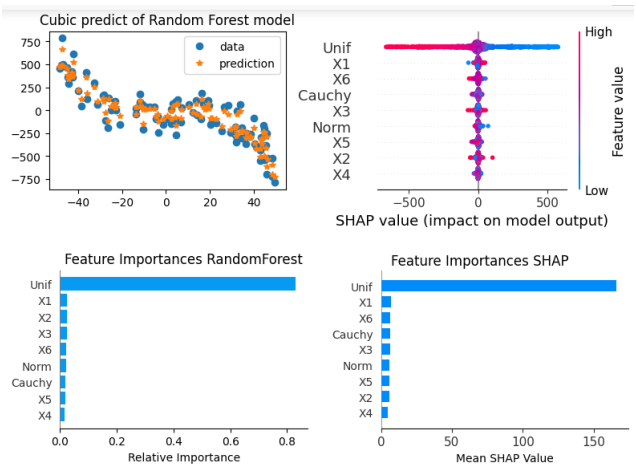

FIGURE 30 – *Cubic*

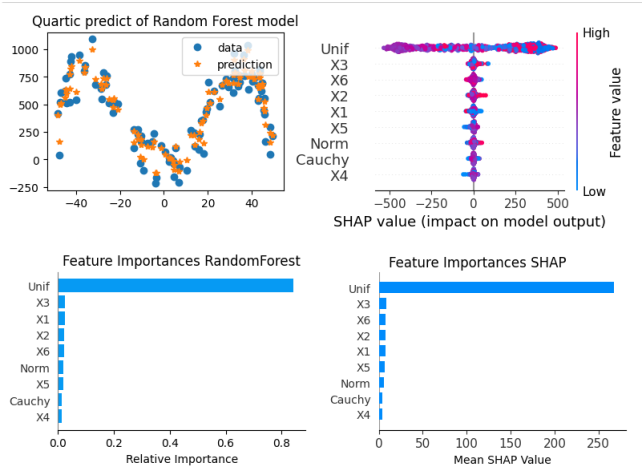

FIGURE 31 – *Quartic*

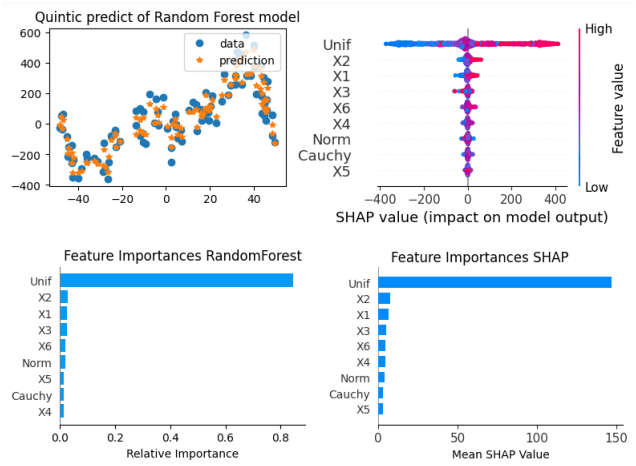

FIGURE 32 – *Quintic*

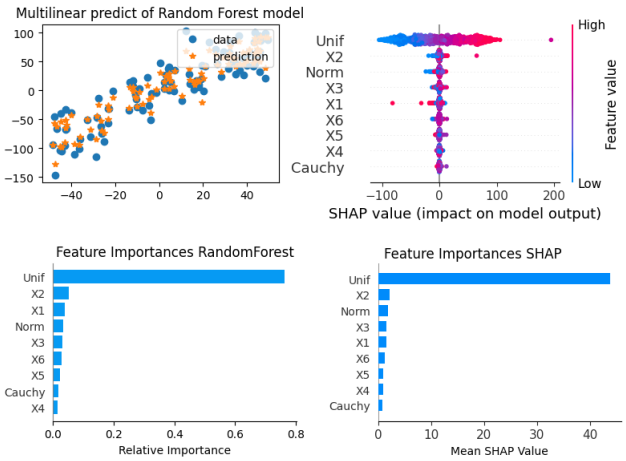

FIGURE 33 – *Multilinear*

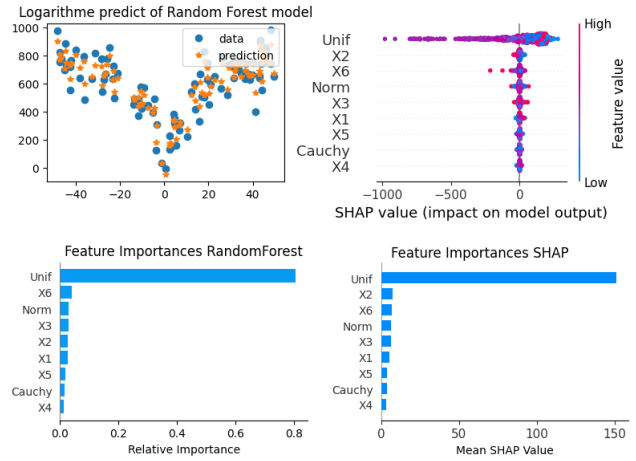

FIGURE 34 – *Logarithmic*

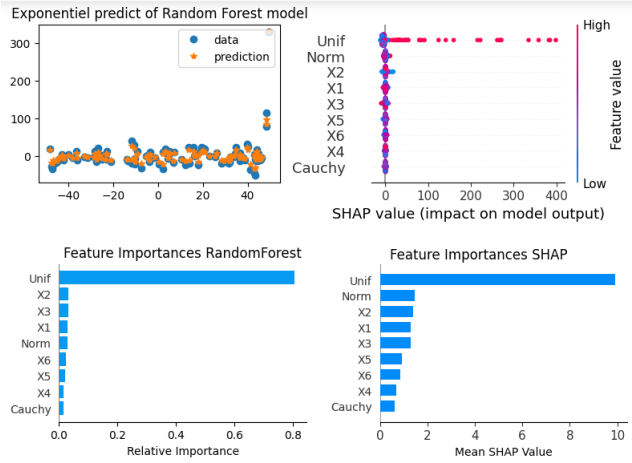

FIGURE 35 – *Exponential*

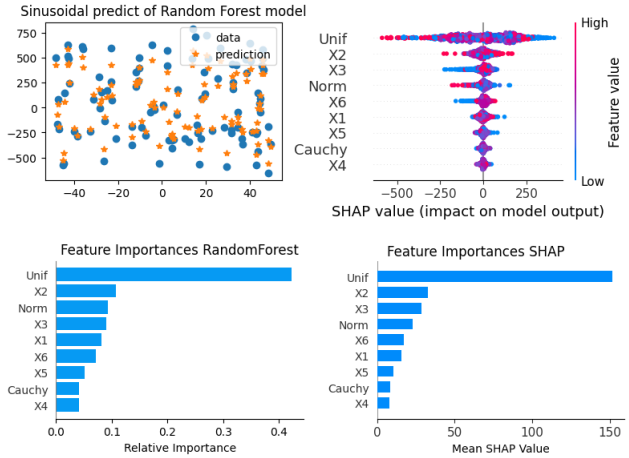

FIGURE 36 – *Sinus*

3.3.3 Inspection visuelle des Shapley Values avec 100% de bruit gaussien

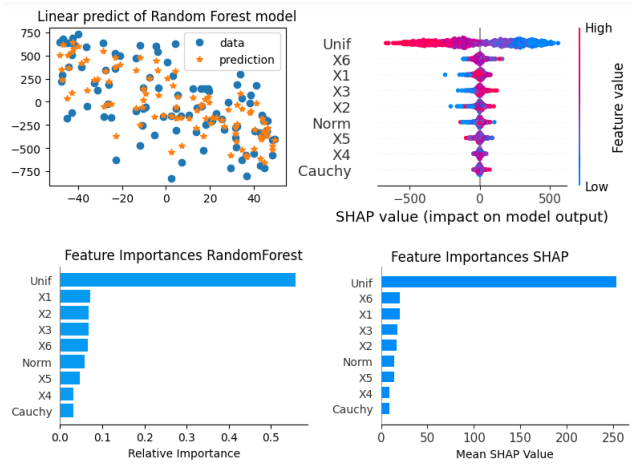

FIGURE 37 – *Linear*

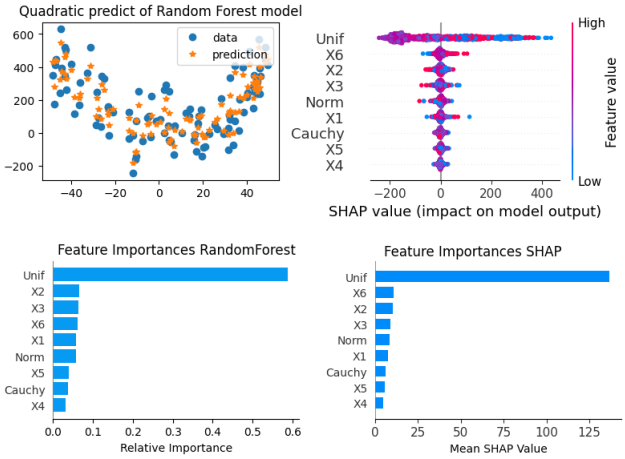

FIGURE 38 – *Quadratic*

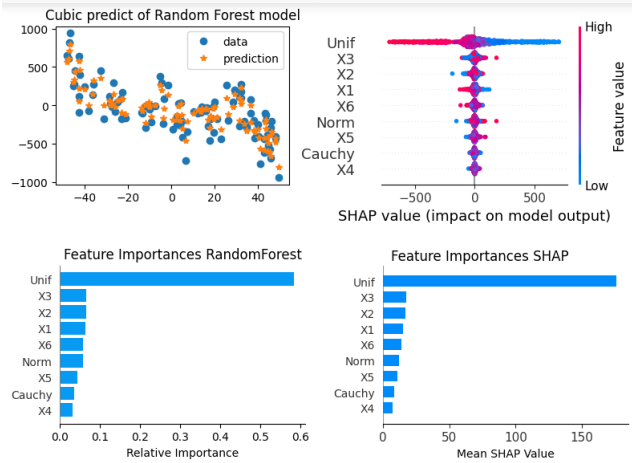

FIGURE 39 – *Cubic*

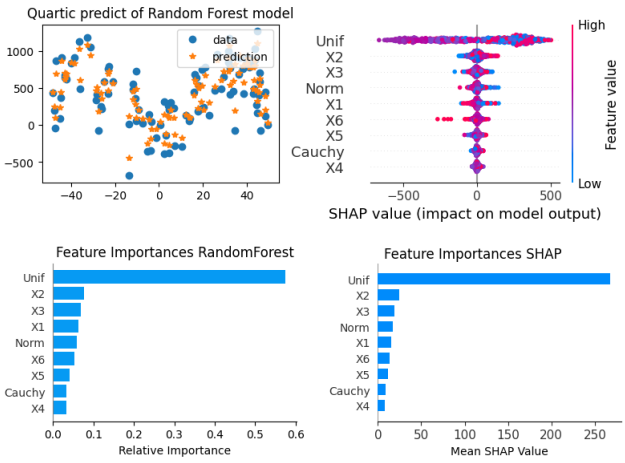

FIGURE 40 – *Quartic*

3.3.4 Interprétation des résultats

L'analyse et l'interprétation des différentes expériences révèlent que les modèles de Feature Importance parviennent à bien détecter la variable explicative (Unif) malgré le bruit gaussien. Par contre, on remarque que les variables fakes deviennent de plus de plus importantes quand le bruit est élevé.
Ce qui affirme que la qualité des résultats de l'algorithme SHAP peut être influencer négativement par la présence du bruit dans les données d'entrées d'un modèle d'AutoML.

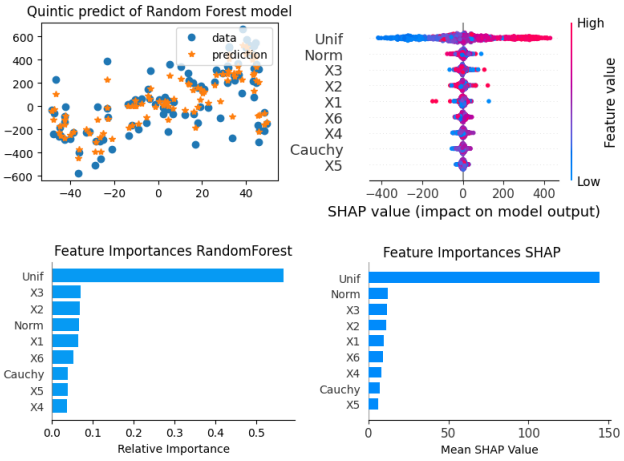

FIGURE 41 – *Quintic*

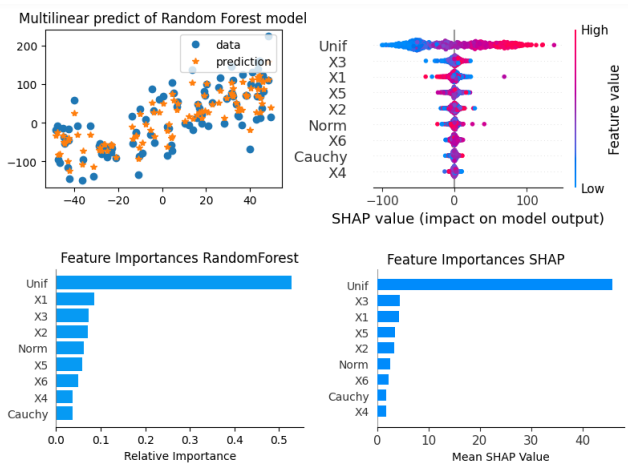

FIGURE 42 – *Multilinear*

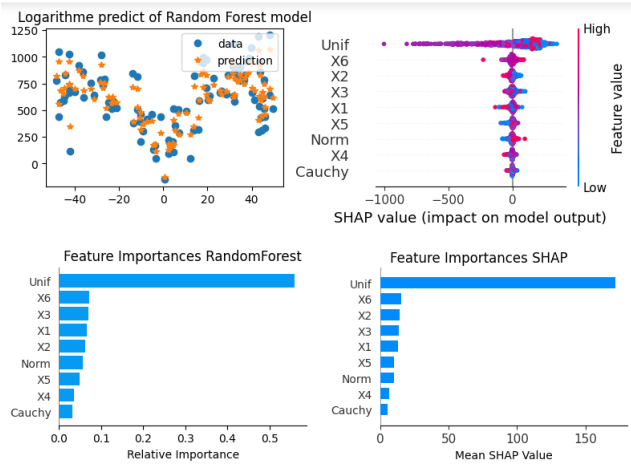

FIGURE 43 – *Logarithmic*

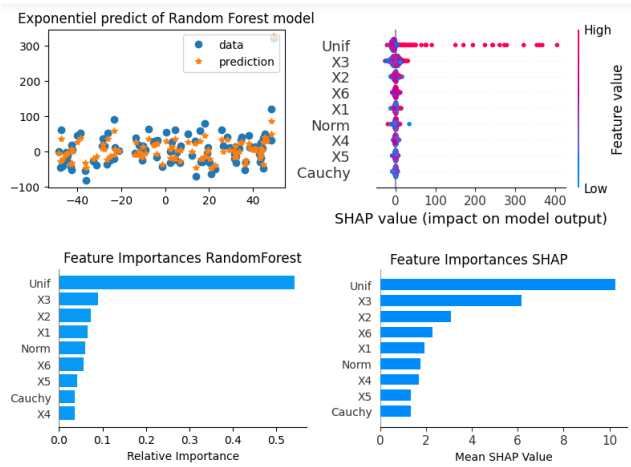

FIGURE 44 – *Exponential*

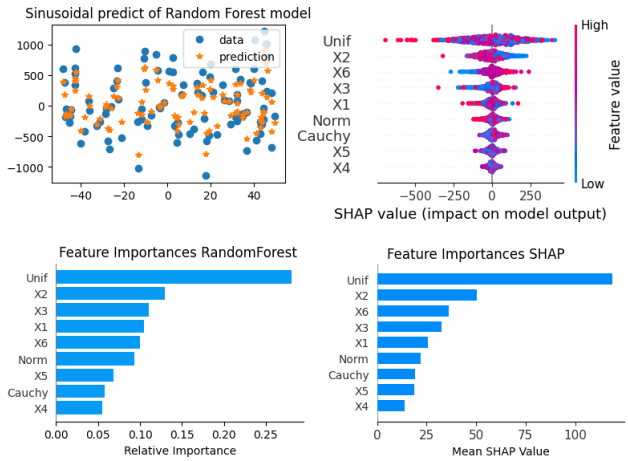

FIGURE 45 – *Sinus*

4 Applications industrielles de l'algorithme SHAP sur des données réelles

4.1 Description du jeu de données réelles

4.1.1 Présentation des données d'entrées : Input Space

Ce dataset Input Space contient les variables explicatives, c'est à dire : les matières premières et certains paramètres importants pour la fabrication industrielle d'un produit cosmétique.

	RM_1	RM_2	RM_3	RM_4	BLOC_1	BLOC_2	PR_temp	PR_speed
0	0.5	4.0	3.5	10	18	28	23	50
1	1.0	0.5	5.0	15	18	28	18	40
2	1.5	1.0	2.0	7	18	28	25	70
3	2.0	1.5	3.5	10	18	28	30	25
4	3.5	2.0	0.5	9	18	28	23	80
5	0.5	0.5	1.0	12	18	28	27	90
6	1.0	1.0	1.5	10	18	28	18	50
7	1.5	1.5	2.0	13	18	28	32	40
8	2.0	2.0	5.0	14	18	28	30	70
9	3.5	3.5	4.0	7	18	28	23	25
10	5.0	0.0	0.5	6	18	28	27	80
11	4.0	0.0	1.0	11	18	28	18	90

FIGURE 46 – Présentation du dataset :Input Space

4.1.2 Présentation des données de sorties : Ouput Space

Alors que le dataset Output Space renferme les variables de réponse, c'est à dire : le coût et les différentes caractéristiques chimico-physiques du produit finale.

	Cost	Visco	Ph	Rheo	Stability	Texture	Senso1	Naturality	Microbio30days
0	128.0	25000	6.920819	67.480662	1	2	2	100.0	649.5
1	137.5	27625	11.792500	16.582639	1	1	3	25.0	546.0
2	55.0	39250	4.110698	54.859325	1	2	3	75.0	1009.0
3	120.5	48875	6.890253	99.770620	0	3	3	92.5	23.5
4	72.0	56500	6.259637	13.420144	0	1	5	85.0	1245.5
5	9.5	31625	9.440692	70.877713	1	3	2	35.0	1377.0
6	37.0	27250	6.500000	64.223469	0	2	3	47.5	737.5
7	74.5	45875	10.103749	50.865358	1	2	3	75.0	289.0
8	178.0	48500	10.756962	89.468562	1	3	4	95.0	929.0
9	188.5	55375	3.785819	98.781719	0	3	4	100.0	147.0
10	66.0	77000	3.187087	57.196641	0	2	5	45.0	1170.5
11	70.0	58000	8.154902	91.396235	0	3	5	10.0	1538.0

FIGURE 47 – Présentation du dataset :Output Space

4.1.3 Présentation des résultats

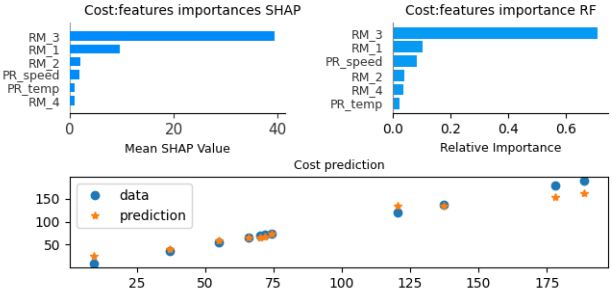

FIGURE 48 – *Cost*

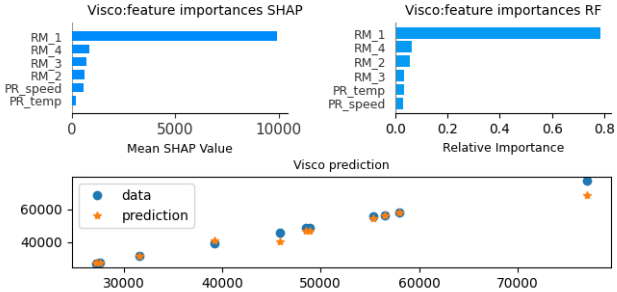

FIGURE 49 – *Visco*

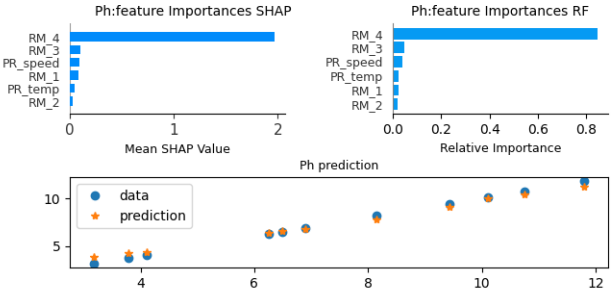

FIGURE 50 – *Ph*

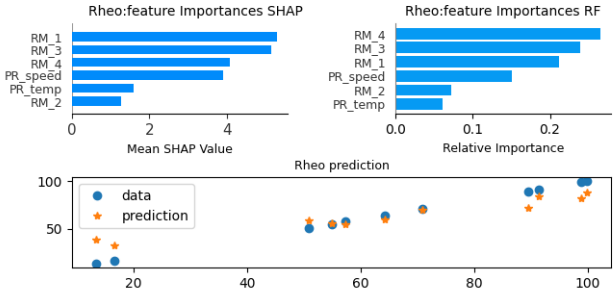

FIGURE 51 – *Rheo*

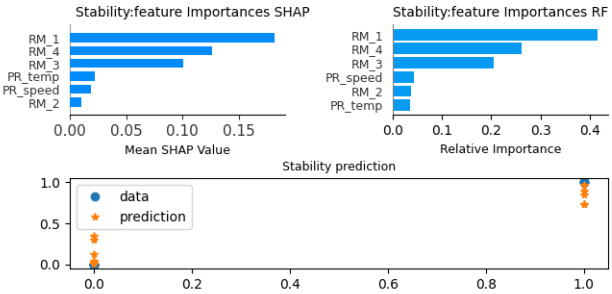

FIGURE 52 – *Stability*

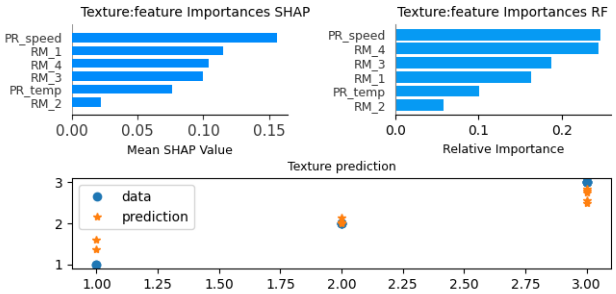

FIGURE 53 – *Texture*

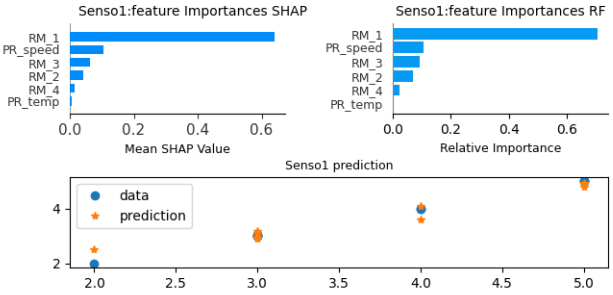

FIGURE 54 – *Senso1*

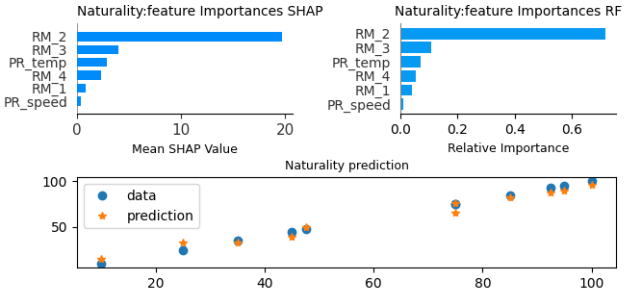

FIGURE 55 – *Naturality*

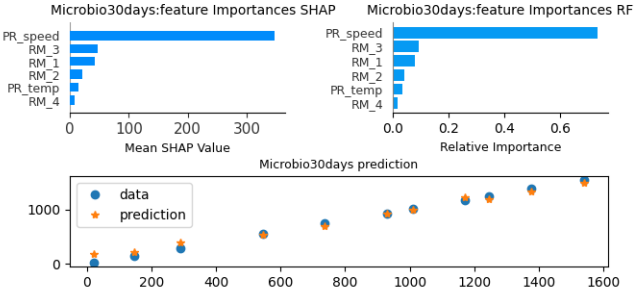

FIGURE 56 – *Microbio30days*

4.1.4 Interprétation des résultats

L'analyse des résultats avec les données réelles, montre que les deux modèles de Feature Importance(SHAP et Random Forest) fournissent plus ou moins les mêmes résultats et parviennent à expliquer pour chaque variable de réponse, la ou les variable(s) les plus influentes, c'est à dire les plus importantes.

Cependant, dans les expériences jumelles, on a remarqué pour certains cas, les résultats de SHAP peuvent être biaisés par la présence des variables fakes.

Alors comment peut-on distinguer les variables importantes et les variables fakes dans les résultats SHAP sur les données réelles ? Et éviter que les résultats soient biaisés.

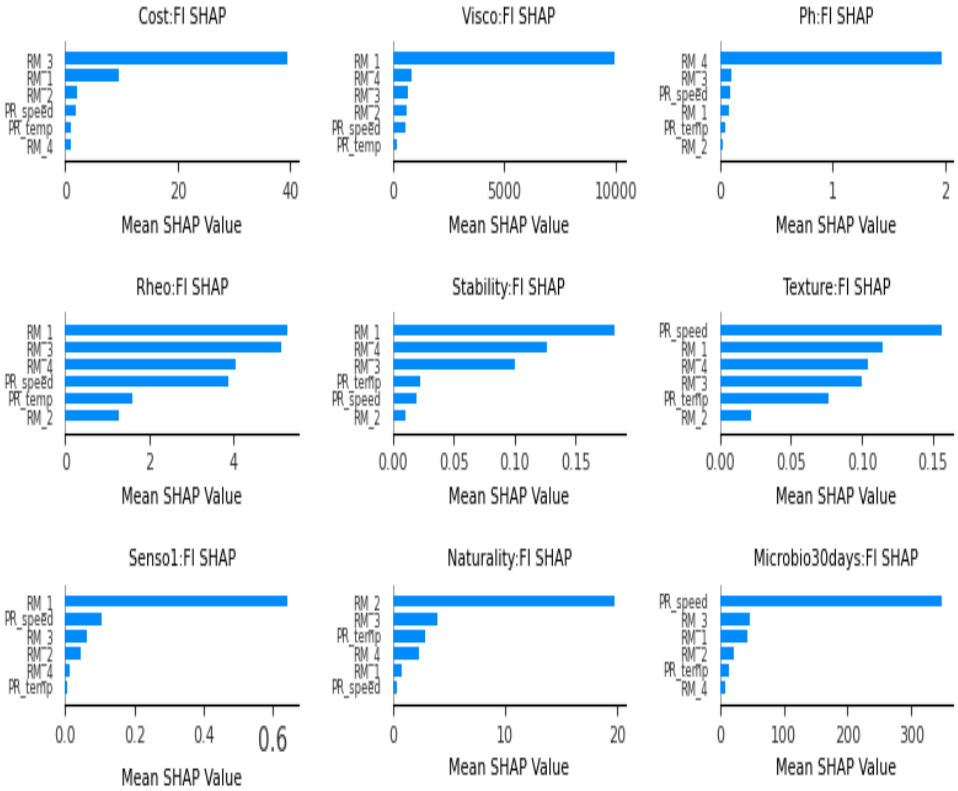

FIGURE 57 – Résumé des features importances avec SHAP

4.2 Application de SHAP sur des données réelles avec des variables fakes

Pour éviter que les résultats de SHAP soient biaisés, nous avons ajouté des fausses variables par **Random Permutation** de chaque variable explicative du dataset Input Space. Ainsi chaque variable explicative a sa variable fake (variable fausse en français) labélisée par la terminaison _fake.

	RM_1	RM_2	RM_3	RM_4	PR_temp	PR_speed	RM_1_fake	RM_2_fake	RM_3_fake	RM_4_fake	PR_temp_fake	PR_speed_fake
0	0.5	4.0	3.5	10	23	50	2.0	2.0	5.0	14	30	70
1	1.0	0.5	5.0	15	18	40	1.0	1.0	1.5	10	18	50
2	1.5	1.0	2.0	7	25	70	1.0	0.5	5.0	15	18	40
3	2.0	1.5	3.5	10	30	25	1.5	1.5	2.0	13	32	40
4	3.5	2.0	0.5	9	23	80	1.5	1.0	2.0	7	25	70
5	0.5	0.5	1.0	12	27	90	0.5	0.5	1.0	12	27	90
6	1.0	1.0	1.5	10	18	50	5.0	0.0	0.5	6	27	80
7	1.5	1.5	2.0	13	32	40	3.5	3.5	4.0	7	23	25
8	2.0	2.0	5.0	14	30	70	3.5	2.0	0.5	9	23	80
9	3.5	3.5	4.0	7	23	25	4.0	0.0	1.0	11	18	90
10	5.0	0.0	0.5	6	27	80	0.5	4.0	3.5	10	23	50
11	4.0	0.0	1.0	11	18	90	2.0	1.5	3.5	10	30	25

FIGURE 58 – Input Space avec ajout des variables fakes

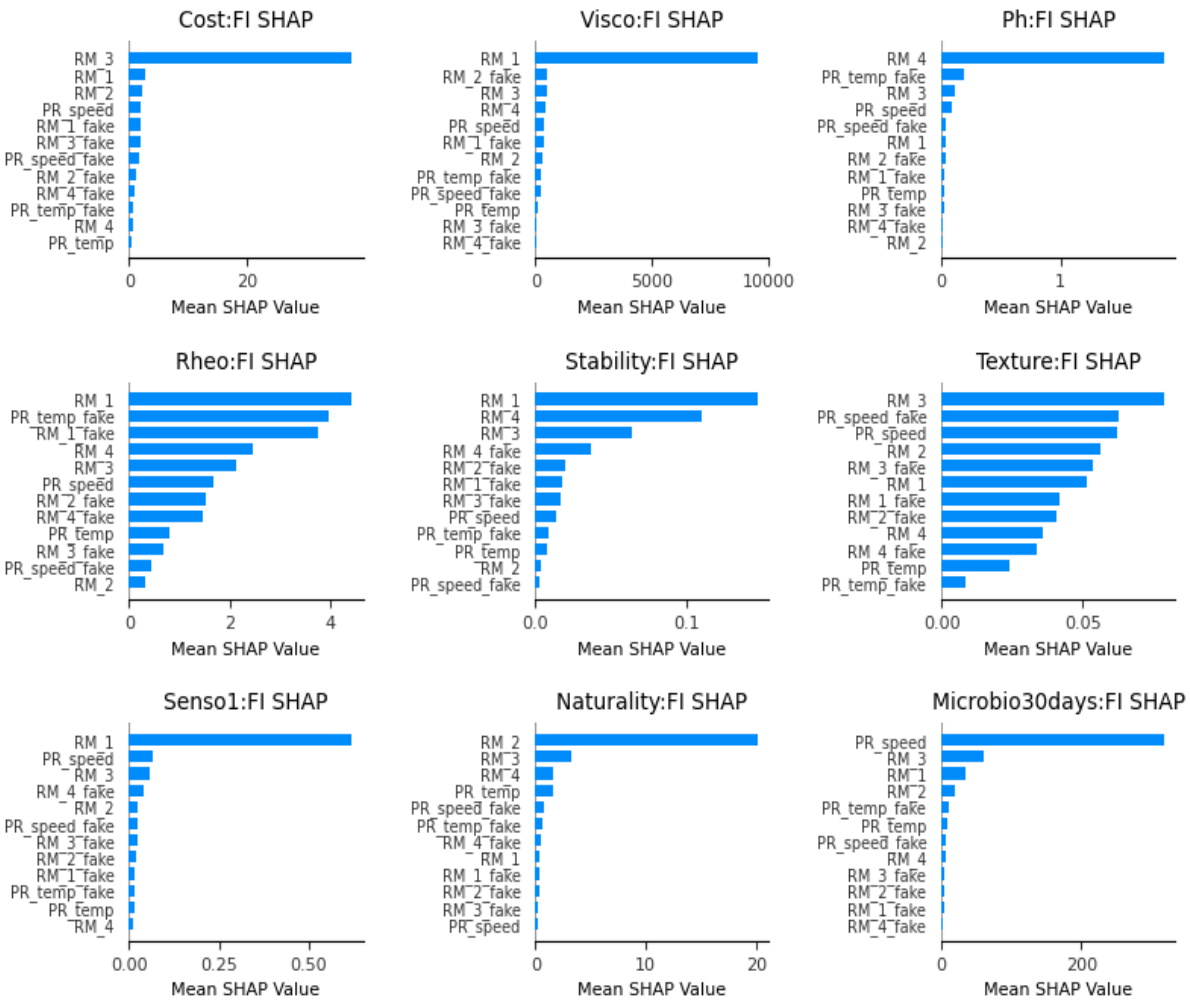

FIGURE 59 – Inspection visuelle des Shapley Values

Ensuite, on procède de la manière suivante pour chaque variable de réponse :

— si la valeur Shapley de la variable explicative est supérieure à celle de sa variable fake, alors on considère que cette variable est importante pour la variable de réponse du Output Space.

— dans le cas contraire, cette variable est considérée comme une variable fake pour la variable de réponse et dans ce cas, sa valeur Shapley devient nulle.

La figure ci-dessous (Figure 60) permet de faire une inspection visuelle des résultats obtenus grâce à cette méthode "filter".

L'analyse de cette figure, montre que la méthode parvient à bien filtrer les variables fakes et de donner de bons résultats qui sont fiables.

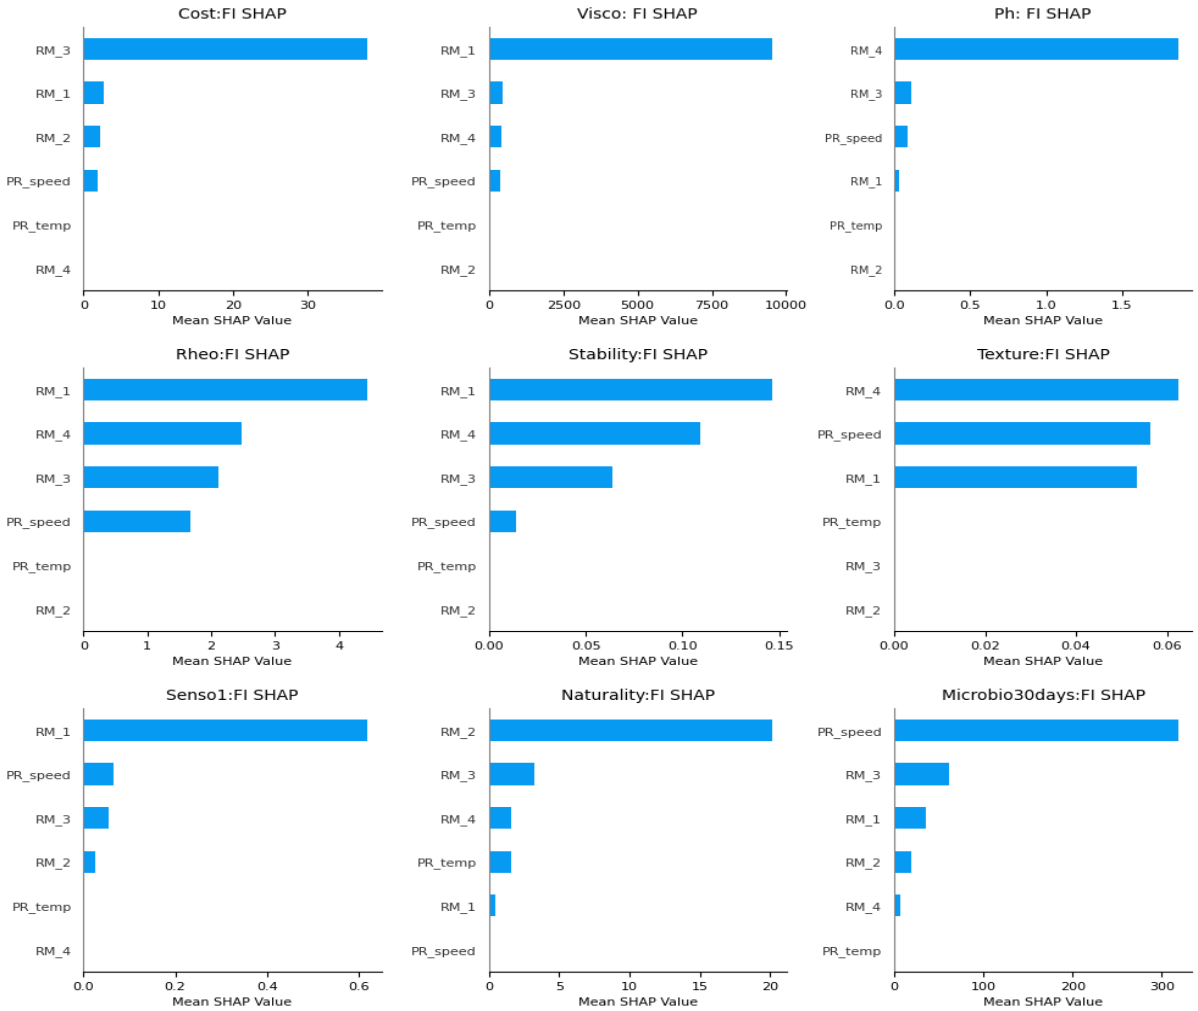

FIGURE 60 – Résultats obtenus grâce à la méthode "filter"

Cependant deux problèmes sont apparus dans les résultats de SHAP liés à sa théorie du jeu coopératif :

— Les valeurs Shapley n'ont pas les mêmes ordres de grandeurs d'une variable à une autre.

— SHAP à un effet dissipatif, c'est à dire que les variables fakes ont tendances à diminuer les valeurs Shapley des variables les plus influentes.

4.3 Uniformisation des Valeurs Shapley par les techniques de Feature Scaling

L'inspection visuelle des différentes expériences ont montré que les valeurs de Shapley n'ont pas les mêmes ordres de grandeurs d'une variable prédictive à une autre. Ce qui suggère qu'il faut uniformiser ces valeurs entre 0 et 1.

Pour pallier à cela, des traitements préparatoires sur les données existent. Notamment le Feature Scaling qui comprend la Standardisation et la Normalisation.

La Normalisation peut-être effectuée par la technique du **Min-Max Scaling**. La transformation se fait grâce à la formule suivante : $X_{normalise} = \frac{X - X_{min}}{X_{max} - X_{min}}$ avec :

— X_{min} : la plus petite valeur observée pour la feature X

— X_{max} : la plus grande valeur observée pour la feature X

— X : La valeur de la feature qu'on cherche à normaliser

La Standardisation est le processus de transformer une feature en une autre qui répondra à la loi normale (Gaussian Distribution) $X \sim \mathcal{N}(\mu, \sigma)$ avec :

— $\mu = 0$ La moyenne de la loi de distribution

— $\sigma = 1$ est L'Écart-type (Standard Deviation)

La formule de standardisation d'une feature est la suivante : $z = \frac{x - \mu}{\sigma}$ avec :

— x la valeur qu'on veut standardiser (input variable)

— μ la moyenne (mean) des observations pour cette feature

— σ est l'écart-type (Standard Deviation) des observations pour cette feature

4.3.1 Inspection visuelle des résultats

Les figures ci-après permettent de faire une inspection comparative des trois résultats de SHAP obtenus avec sans prétraitement, avec la normalisation et enfin avec la standardisation.

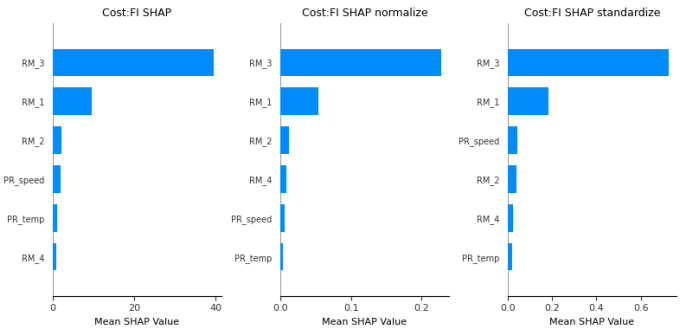

FIGURE 61 – *Cost*

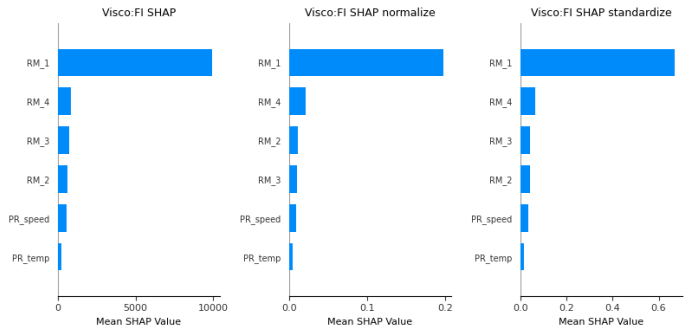

FIGURE 62 – *Visco*

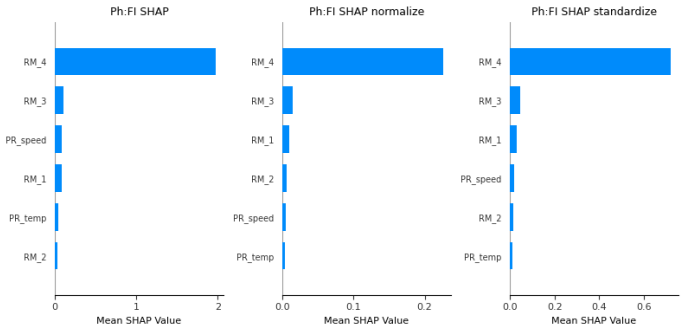

FIGURE 63 – *Ph*

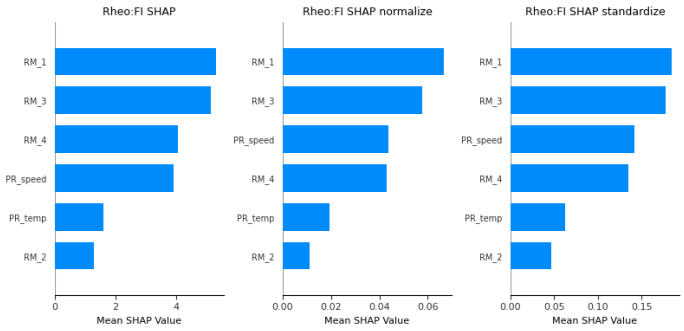

FIGURE 64 – *Rheo*

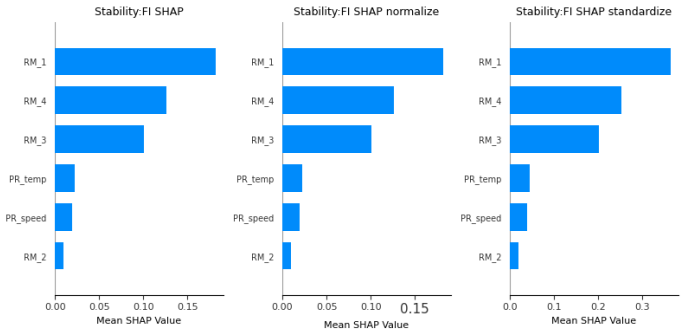

FIGURE 65 – *Stability*

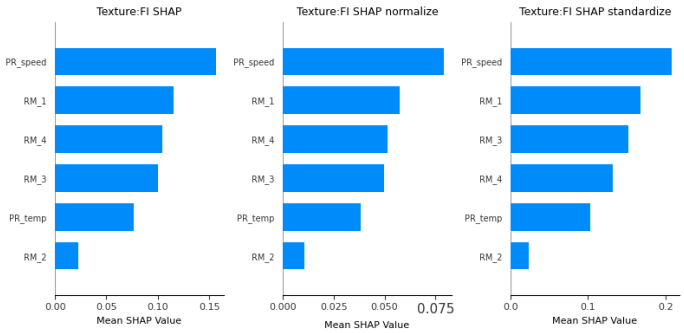

FIGURE 66 – *Texture*

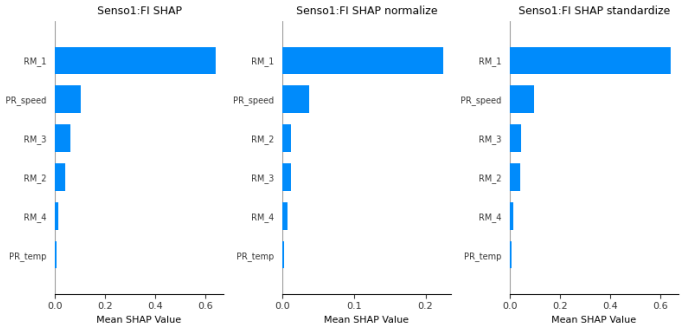

FIGURE 67 – *Senso1*

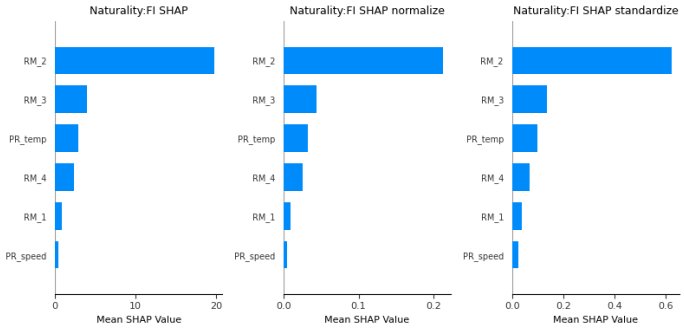

FIGURE 68 – *Naturality*

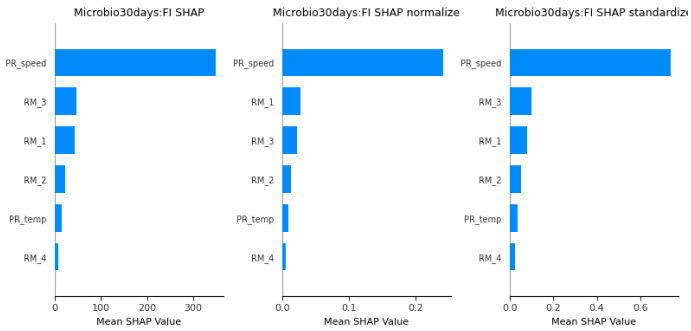

FIGURE 69 – *Microbio30days*

4.3.2 Interprétation des résultats

En observant les différents résultats, on remarque que la Normalisation et la Standardisation n'altèrent pas les résultats de l'algorithme SHAP sur l'importance des variables.
Cependant, les valeurs de Shapley sont distribuées uniformément dans l'intervalle $[0, 1]$ avec la standardisation des données réelles.
Donc on peut retenir qu'avec la standardisation, on parvient à avoir des valeurs de Shapley plus interprétable par les formulateurs et les chimistes.

4.4 Réduction des effets dissipatifs de SHAP

Pour atténuer l'effet dissipatif de l'algorithme SHAP dans le but d'une amélioration et la fiabilisation de la qualité des résultats, une deuxième utilisation de SHAP est nécessaire.
Elle consiste à sélectionner pour chaque variable de réponse, les variables les plus influentes lors de la première application de SHAP dans l'Input Space.

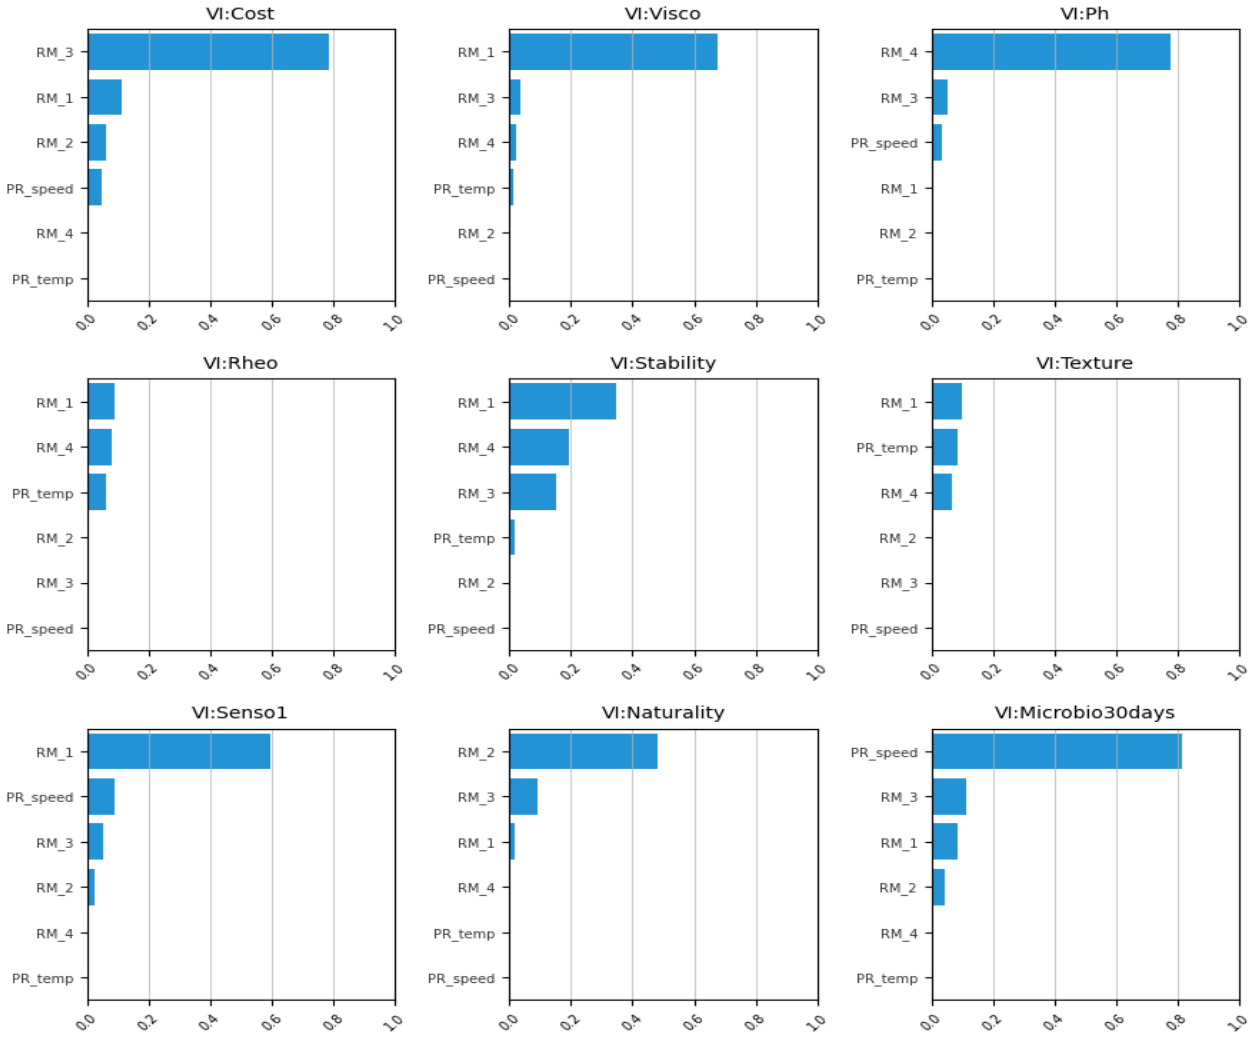

FIGURE 70 – Présentation visuelle des résultats après la première application de SHAP

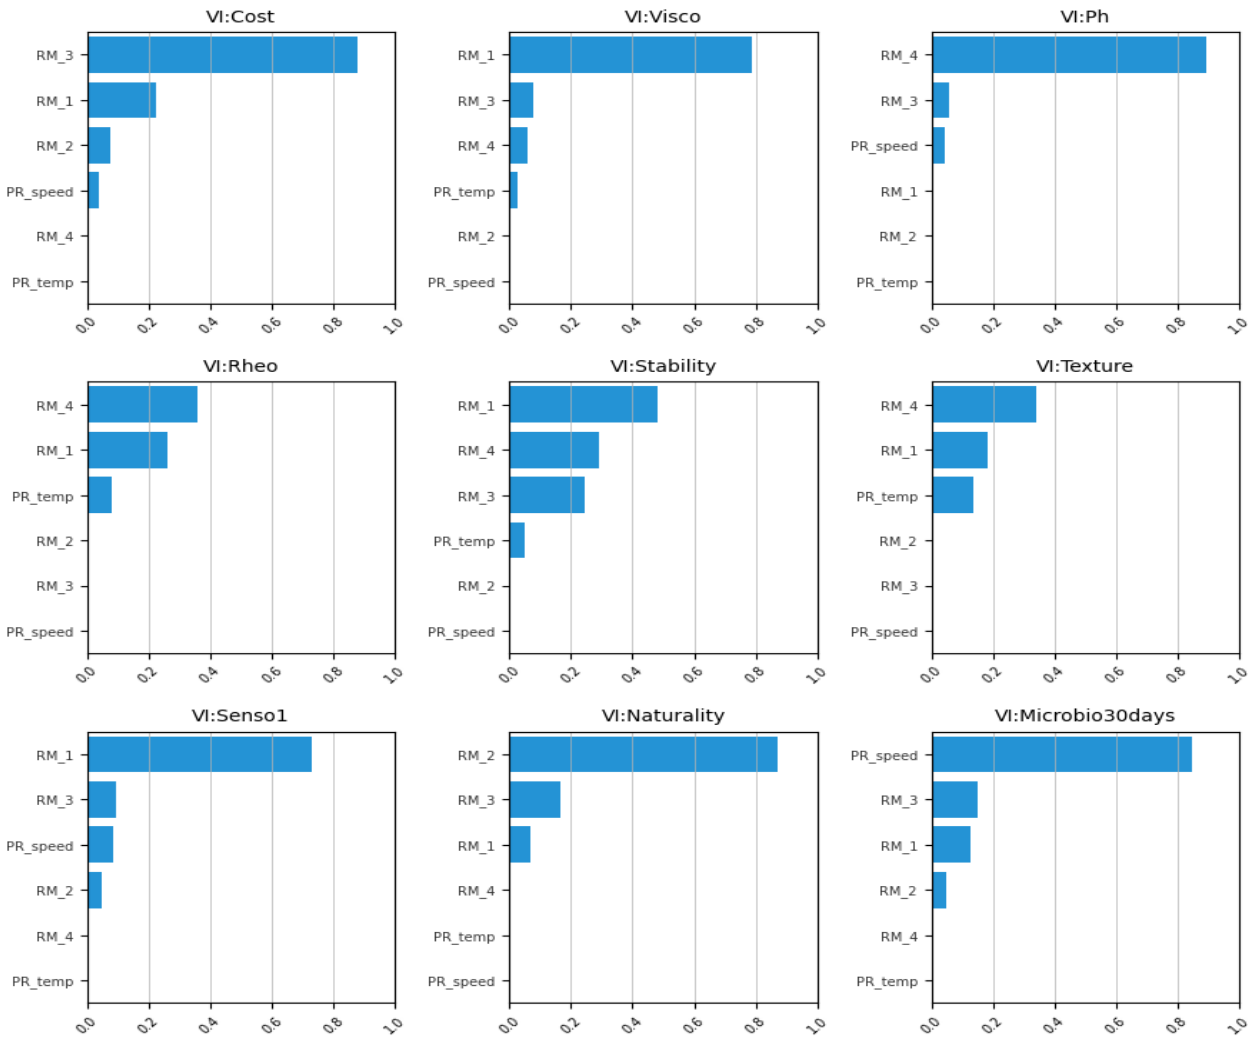

FIGURE 71 – Présentation visuelle des résultats après la deuxième application de SHAP

On voit que la deuxième passe de SHAP a permis d'obtenir des diagrammes de Pareto beaucoup plus importants par rapport aux variables les plus influentes.
Donc l'effet dissipatif disparaît grâce à une deuxième application de l'algorithme SHAP qui prend en compte que les variables importantes de la première application.

La figure ci-dessous (FIGURE 72) permet une visualisation matricielle des Shapley Values obtenues grâce à la deuxième passe et donne un meilleur aperçu de la qualité des résultats.

FIGURE 72 – Présentation de la matrice des Shapley Values avec les données réelles

5 Conclusion

Au cours des six mois de stage au sein d'InFLOWS AI, nous avons étudier l'applicabilité de l'algorithme SHAP dans un pipeline d'AutoML appliqué à la chimie de formulation.
SHAP est une nouvelle méthode de sélection de variable basée sur la théorie du jeu coopératif appliquée en Machine Learning pour la sélection automatique des variables dans les processus d'AutoML.
La finalité de ce travail est de permettre aux industries chimiques et agroalimentaires de se doter des logiciels et des boîtes à outils de formulation assistées par ordinateur très performants, permettant d'augmenter la rentabilité en réduisant les coûts et de concevoir dans un court délai un nouveau produit commercial.
Les compétences acquises au cours de ma formation m'ont permis non seulement de comprendre la problématique formulée scientifiquement et les méthodes mises en œuvre pour y répondre, mais aussi de pouvoir donner une interprétation des résultats obtenus dans les différentes expériences théoriques avec les données jumelles et une application réelle avec des données industrielles.
L'analyse et l'interprétation de ces différentes expériences ont permis de mettre en place un pipeline d'AutoML qui implémente déjà l'algorithme SHAP pour résoudre en parallèle le problème de la sélection des variables au cours des processus d'AutoML.
Au terme de ce travail, nous avons pu régler quelques insuffisances de SHAP liées à sa théorie des jeux coopératifs et contourner certaines difficultés de son applicabilité par le fait qu'il a du mal dans certains cas d'identifier les vraies variables et les fausses variables surtout en présence du bruit. Ce qui nécessite en perspective, d'autres travaux supplémentaires de Data-Scientist pour mieux l'adapter à notre cas et faire de SHAP une méthode incontournable d'interprétabilité et de sélection de variables en Machine Learning.

Références

[1] S.Lundberg and S. L.Lee (2017), A unified appoach to interpreting model predictions ;https://www.quantmetry.com/blog/valeurs-de-shapley/

[2] Christoph Molnar (2021),Interpretable Machine Learning ; https://christophm.github.io/interpretable-ml-book/

[3] L. S. Shapley (1953), A value for n-person games.Contributions to the Theory of Games, pages 307–317

[4] Jules Goueffon (2018-2019),Rapport PFE Data Scientiste chez DS-SPHERE

[5] Alex Goldstein, Adam Kapelnery, Justin Bleichz and Emil Pitkinx (2014), Peeking Inside the Black Box : Visualizing Statistical Learning with Plots of Individual Conditional Expectation.

[6] Miller, Tim. (2017),"Explanation in artificial intelligence : Insights from the social sciences." arXiv Preprint arXiv :1706.07269.

[7] Lundberg, Scott et al.,« Consistent individualized feature attribution for tree ensembles»(2019) ; https://arxiv.org/pdf/1802.03888.pdf

[8] Alain Durand, JIREC 2015 : « La formulation aujourd'hui : une introduction»

[9] PhD Jason Brownlee, August 20, 2020, «How to Choose a Feature Selection Method For Machine Learning», "Machine Learning Mastery" ; https://machinelearningmastery.com/feature-selection-with-real-and-categorical-data/

[10] Ph.D Abdou Kane, site web InFLOWS AI https://inflows-ai.com/

[11] Jacques GOUPY (2006), Tutoriel : LES PLANS D'EXPERIENCES ; Revue MODULAD Numéro 34.

[12] Wikipedia, Automated machine learning (AutoML) ; https://en.wikipedia.org/wiki/Automated_machine_learning

[13] towards Data Science, https://towardsdatascience.com/