Rapport Big Data avec Hadoop-Spark

Traitement et Analyse des Tweets

Mastère Spécialisé

Calcul hautes performances/Données massives /Intelligence artificielle

Réalisé par:
Paul Diokine BATISTA
Enseignant:
Fabrice Mourlin

June 11, 2022

Contents

1 Introduction **3**

2 Écosystème Apache Spark **3**
2.1 Spark SQL 4
2.2 Spark Streaming 4
2.3 Spark Graph X 4
2.4 Spark MLlib 4

3 Architecture logicielle **4**
3.1 Création d'une application Twitter par l'API-Twitter 5
3.2 Tweepy 6

4 Traitement et analyse des tweets **6**
4.1 Streamer des tweets à partir de l'API de Twitter 6
4.1.1 Streamer les tweets et stockage 6
4.1.2 Streamer puis stocker les tweets en dataframe 6
4.2 Analyse et visualisation des tweets 9
4.2.1 Visualisation des tweets de Ousmane Sonko 9
4.2.2 Visualisation des tweets de Macky Sall 11
4.3 Analyse des sentiments des données tweets 13
4.3.1 Analyse des sentiments des tweets de Ousmane Sonko 14
4.3.2 Analyse des sentiments des tweets de Macky Sall 15

5 Conclusion **16**

6 Annexe: Les scriptes en Python **17**
6.1 Annexe 1: Streamer les tweets et stockage 17
6.2 Annexe 2: Streamer puis stocker les tweets en dataframe 18
6.3 Annexe 3:Analyse et visualisation des données tweets 18
6.4 Annexe 4: Analyse des sentiments des données tweets 22

Liste des figures

1 l'écosystème Apache Spark est ces différentes interactions dans le Big-Data 3
2 Schéma du fonctionnement de Spark Streaming 4
3 Architecture logicielle du programme Python 5
4 Capture d'écran de mon compte Developeur permettant d'obtenir une clé et un jeton de l'API Twitter 5
5 Capture d'écran de l'extraction en streaming des données brutes de twitter 6
6 Twitter in a DataFrame 7
7 Dataframe des tweets de Ousmane Sonko 9
8 Les courbes d'évolutions des likes et des retweets en fonction de la date 9
9 Histogrammes des likes en fonction de la date 10
10 Histogrammes des retweets en fonction de la date 10
11 Dataframe des tweets de Macky Sall 11
12 Les courbes d'évolutions des likes et des retweets en fonction de la date 11
13 Histogrammes des likes en fonction de la date 12
14 Histogrammes des retweets en fonction de la date 12
15 Dataframe des sentiments de Ousmane Sonko par tweet 14
16 Courbe d'évolution de la polarité des sentiments en fonction de la date 14
17 Dataframe des sentiments de Macky Sall par tweet 15
18 Courbe d'évolution de la polarité des sentiments en fonction de la date 15

1 Introduction

Les réseaux sociaux sont aujourd'hui parmi les plus grandes sources de données, ce qui signifie qu'ils sont un atout extrêmement précieux pour les spécialistes du marketing, les spécialistes du big data et même les utilisateurs individuels comme les journalistes et autres professionnels. Exploiter le potentiel des données Twitter en temps réel est également utile dans de nombreux processus commerciaux sensibles au facteur temps.
C'est ainsi, **Apache Spark** et **Python** offrent des bibliothèques efficaces pour extraire puis stocker ces grandes quantités de données en temps réel et effectuer diverses analyses sur ces données.
De nombreuses ressources traitent de Spark et de sa popularité dans le domaine du big data, mais il convient de souligner que ses principales fonctionnalités comprennent le traitement en temps réel des big data à l'aide de RDD (Resilient Distributed Datasets), le streaming et l'apprentissage automatique.
Dans ce rapport, nous allons utiliser quelques modules de python ou de PySpark de Apache Spark pour extraire puis analyser les Tweets.

2 Écosystème Apache Spark

Apache Spark est un framework open source de calcul distribué. Il s'agit d'un ensemble d'outils et de composants logiciels structurés selon une architecture définie. Développé à l'université de Californie à Berkeley par AMPLab3, Spark est aujourd'hui un projet de la fondation Apache. Ce produit est un cadre applicatif de traitements big data pour effectuer des analyses complexes à grande échelle.
L'écosystème Apache Spark est un framework de calcul en cluster distribué open source. Spark est un moteur de traitement de données développé pour fournir des analyses plus rapides et plus faciles que Hadoop MapReduce.

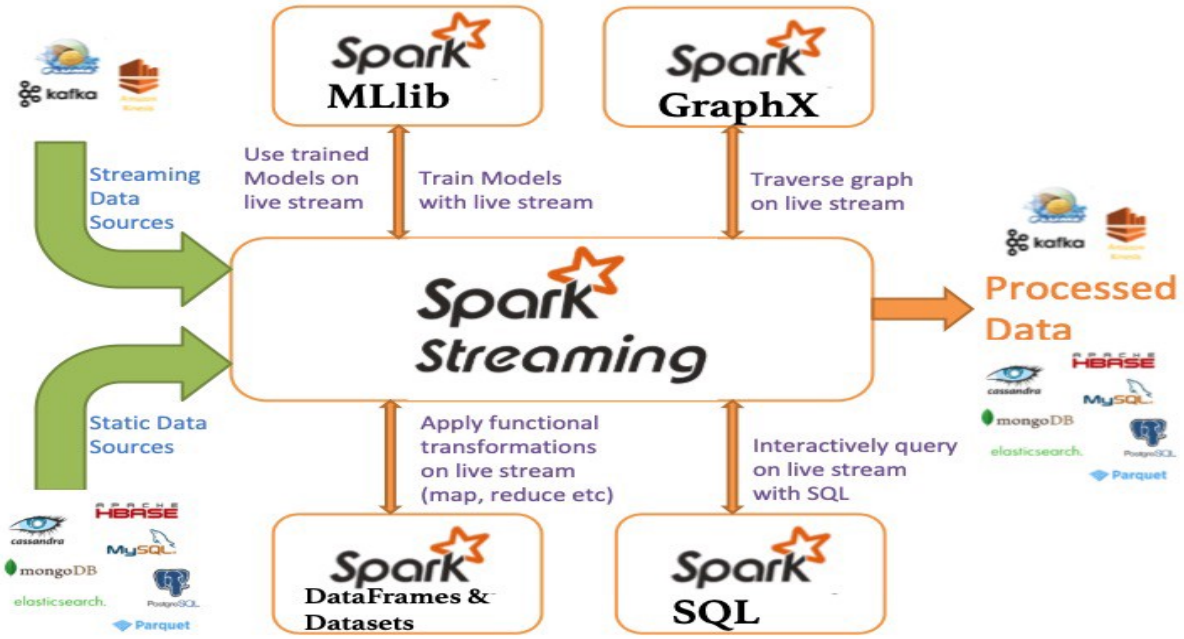

Figure 1: l'écosystème Apache Spark est ces différentes interactions dans le Big-Data

2.1 Spark SQL

Spark SQL permet d'exécuter des requêtes en langages SQL pour charger et transformer des données. Le langage SQL est issu des bases de données relationnelles, mais dans Spark, il peut être utilisé pour traiter n'importe quelles données, quel que soit leur format d'origine.

2.2 Spark Streaming

Spark Streaming offre à son utilisateur un traitement des données en flux. Il utilise les données en temps-réel DStream (discretized stream) c'est-à-dire une série continue de RDD. Par exemple Twitter ou Amazon Kinesis.

Figure 2: Schéma du fonctionnement de Spark Streaming

2.3 Spark Graph X

Spark Graph X permet de traiter les informations issues de graphes. Graph X étend les RDD de Spark en introduisant le resilient distributed dataset graph, un multi-graphe orienté avec des propriétés attachées aux nœuds et aux arêtes.

2.4 Spark MLlib

C'est une bibliothèque d'apprentissage automatique, apparu dans la version 1.2 de Spark, qui contient tous les algorithmes et utilitaires d'apprentissage classiques, comme la classification, la régression, le clustering, le filtrage collaboratif et la réduction de dimensions, en plus des primitives d'optimisation sous-jacentes. On parle souvent d'une fouille de données par apprentissage statistique.

3 Architecture logicielle

Twitter est un réseau social populaire où les utilisateurs partagent des messages appelés tweets. Twitter nous permet d'exploiter les données de tout utilisateur en utilisant l'API Twitter ou Tweepy. Les données seront des tweets extraits de l'utilisateur. La première chose à faire est d'obtenir la clé du consommateur, le secret du consommateur, la clé d'accès et le secret d'accès du développeur Twitter facilement disponibles pour chaque utilisateur. Ces clés aideront l'API pour l'authentification.

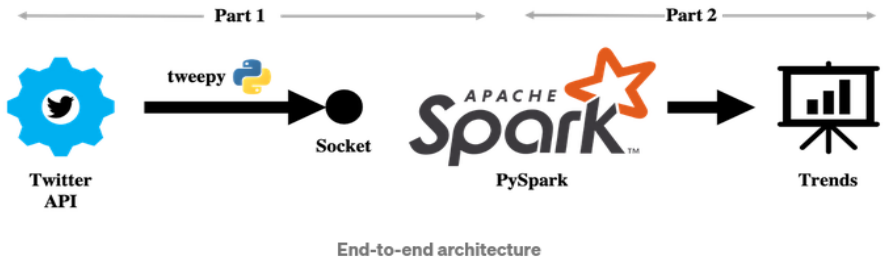

Figure 3: Architecture logicielle du programme Python

3.1 Création d'une application Twitter par l'API-Twitter

Une **API**, ou Application Programming Interface, est une série de méthodes mise à disposition par un site à des développeurs tiers, leur permettant d'utiliser certaines fonctionnalités ou d'accéder à des données du site. Twitter dispose de plusieurs APIs permettant de requêter sa base de données, mais aussi de construire des services au-dessus de sa plateforme. Pour faire simple, les deux APIs les plus utilisées sont: **l'API REST 1.1** qui retourne des données historiques et **l'API Streaming** qui fonctionne comme un enregistreur.
La création d'une application Twitter se fait en remplissant toutes les conditions dans le site: `https://apps.twitter.com/` pour obtenir une clé d'accès à l'API et un jeton d'accès. Il s'agit respectivement des champs consumer key / consumer secret et access token / access token secret.

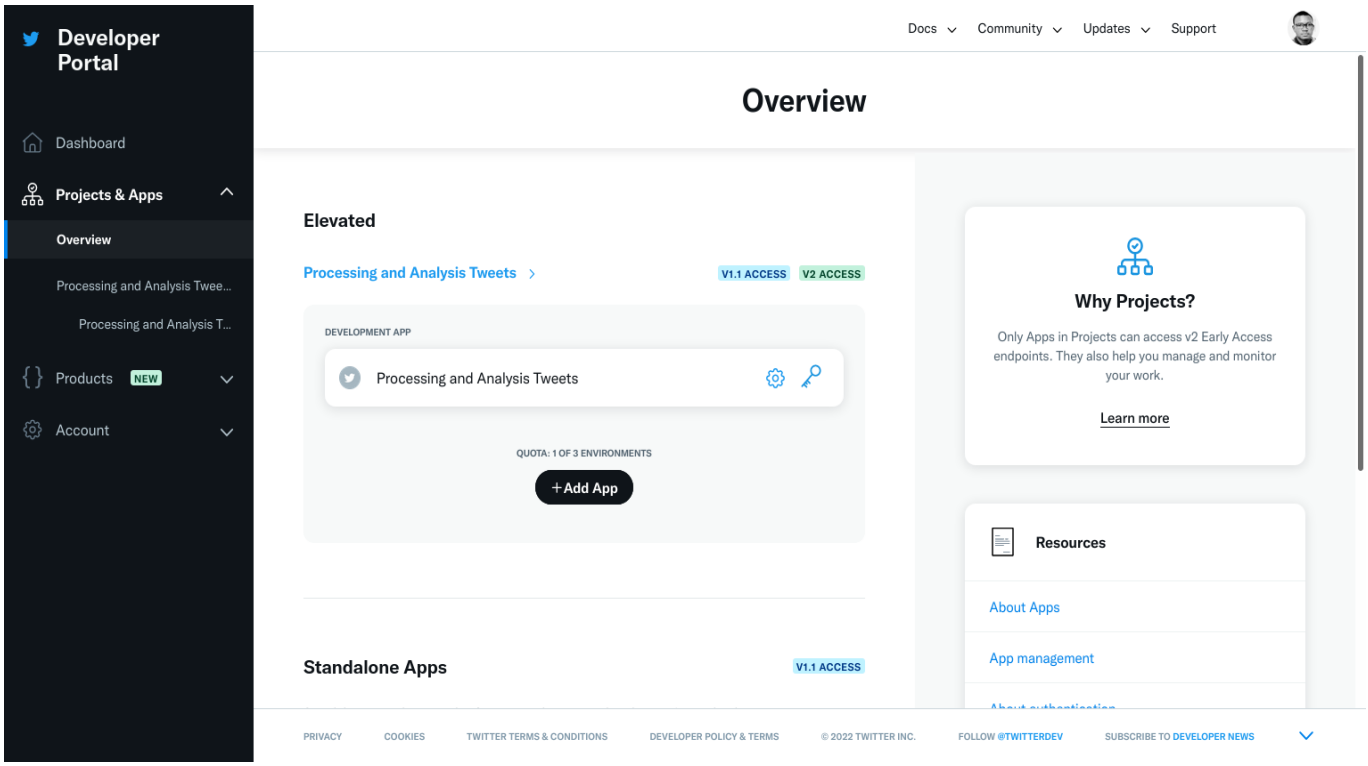

Figure 4: Capture d'écran de mon compte Developeur permettant d'obtenir une clé et un jeton de l'API Twitter

3.2 Tweepy

Tweepy est une bibliothèque Python conçue en 2013 par Joshua Roesslein. Elle permet d'interroger de façon très simple l'API Twitter afin de récupérer les Tweets. Le nom Tweepy est l'association des mots Twitter et Python : Twitter + Python = Tweepy.

4 Traitement et analyse des tweets

4.1 Streamer des tweets à partir de l'API de Twitter

Dans cette section, nous allons d'abord streamer les tweets et les stocker en format txt ou csv, ensuite nous allons streamer les tweets selon un théme d'actualité ou un sujet particulier (#hashtags).

4.1.1 Streamer les tweets et stockage

```python
        except BaseException as e:
            print("Error on_data %s" % str(e))
        return True


    def on_error(self, status):
        print(status)

if __name__ == '__main__':

    # Authenticate using config.py and connect to Twitter Streaming API.
    hash_tag_list = ["Macky Sall", "Ousmane Sonko", "Khalifa Sall", "Barthélémy Dias"]
    fetched_tweets_filename="tweets.txt" #  ou en tweets.csv

    twitter_streamer = TwitterStreamer()
    twitter_streamer.stream_tweets(fetched_tweets_filename, hash_tag_list)
```


```
{"created_at":"Fri Jun 10 17:51:07 +0000 2022","id":1535318658003701760,"id_str":"1535318658003701760","text":"RT
@SambaSambaRio: Na gnou yAllah diappalei gnou dieul\u00e9 fi bepp galankoor bou teuyy\u00e9 sunu rewmi.\n\nJammou
Senegal yAllah na soutt ay fann b\u2026","source":"\u003ca href=\"http:\/\/twitter.com\/download\/android\" rel=\"
nofollow\"\u003eTwitter for Android\u003c\/a\u003e","truncated":false,"in_reply_to_status_id":null,"in_reply_to_st
atus_id_str":null,"in_reply_to_user_id":null,"in_reply_to_user_id_str":null,"in_reply_to_screen_name":null,"use
r":{"id":897825603835113472,"id_str":"897825603835113472","name":"Mouhamad Lamine Kane","screen_name":"GadioOumou
l","location":"Senegal ","url":"https:\/\/thilognedierryblog.worpress.com","description":"Electronicien  ThilogneD
ierry Entreprise","translator_type":"regular","protected":false,"verified":false,"followers_count":2794,"friends_c
ount":2513,"listed_count":34,"favourites_count":377,"statuses_count":576221,"created_at":"Wed Aug 16 14:21:19 +000
0 2017","utc_offset":null,"time_zone":null,"geo_enabled":true,"lang":null,"contributors_enabled":false,"is_transla
tor":false,"profile_background_color":"000000","profile_background_image_url":"http:\/\/abs.twimg.com\/images\/the
mes\/theme1\/bg.png","profile_background_image_url_https":"https:\/\/abs.twimg.com\/images\/themes\/theme1\/bg.pn
g","profile_background_tile":false,"profile_link_color":"1B95E0","profile_sidebar_border_color":"000000","profile_
sidebar_fill_color":"000000","profile_text_color":"000000","profile_use_background_image":false,"profile_image_ur
l":"http:\/\/pbs.twimg.com\/profile_images\/1418299964040560644\/ePEOBmoE_normal.jpg","profile_image_url_https":"h
ttps:\/\/pbs.twimg.com\/profile_images\/1418299964040560644\/ePEOBmoE_normal.jpg","profile_banner_url":"https:\/\/
pbs.twimg.com\/profile_banners\/897825603835113472\/1649793989","default_profile":false,"default_profile_image":fa
lse,"following":null,"follow_request_sent":null,"notifications":null,"withheld_in_countries":[]},"geo":null,"coord
inates":null,"place":null,"contributors":null,"retweeted_status":{"created_at":"Thu Jun 09 09:51:03 +0000 2022","i
```


Figure 5: Capture d'écran de l'extraction en streaming des données brutes de twitter

4.1.2 Streamer puis stocker les tweets en dataframe

Dans cette rubrique, il s'agit de streamer les tweets selon un théme ou un sujet d'actualité, ensuite les stocker dans une base de données en dataframe grâce à la bibliothèque **advertools** qui est trés utilisée en Marketing digital.

Exemple: les tweets sur le théme: Actualité

Figure 6: Twitter in a DataFrame

Entrée [1]:

```python
# get these from your dashboard on developer.twitter.com:
auth_params = {
    'app_key': "k8WtNYDfJt7D5WYX4KKQ2CqFM",
    'app_secret': "wmz9QIFnpXQa7jsFmHypOb8koAygZvdWNbWDVKWBcx5WAnSAW2",
    'oauth_token':"1511746246494593032-u3t18TrXTsBT5SNqwh7yRNx1RW7AmA",
    'oauth_token_secret': "3JJzKQFI7O5lu2qs4ks4sQQn1ximGeKMYUPJg5sFgtpyb",
}

# twython:
from twython import Twython
twitter = Twython(**auth_params)
twitter.search(q='Actualité')
# or any other function and / or parameters

# advertools:
import advertools as adv
adv.twitter.set_auth_params(**auth_params)
adv.twitter.get_user_timeline(screen_name='twitter')
# or some other function

python = adv.twitter.search(q='Actualité', count=1000, tweet_mode='extended', lang='fr')
python.to_csv('python_tweets.csv', index=False)
```

```
2022-06-10 18:49:23,826 | INFO | twitter.py:236 | wrapper | get_user_timeline | Requesting: count=200, max_id=None,
screen_name=twitter
2022-06-10 18:49:24,788 | INFO | twitter.py:236 | wrapper | search | Requesting: count=100, max_id=None, q=Actualit
é, tweet_mode=extended, lang=fr
2022-06-10 18:49:25,737 | INFO | twitter.py:236 | wrapper | search | Requesting: count=100, max_id=15353305728176496
65, q=Actualité, tweet_mode=extended, lang=fr
2022-06-10 18:49:26,388 | INFO | twitter.py:236 | wrapper | search | Requesting: count=100, max_id=15353274016888340
47, q=Actualité, tweet_mode=extended, lang=fr
2022-06-10 18:49:27,048 | INFO | twitter.py:236 | wrapper | search | Requesting: count=100, max_id=15353246584169472
01, q=Actualité, tweet_mode=extended, lang=fr
2022-06-10 18:49:27,761 | INFO | twitter.py:236 | wrapper | search | Requesting: count=100, max_id=15353219004732620
79, q=Actualité, tweet_mode=extended, lang=fr
2022-06-10 18:49:28,478 | INFO | twitter.py:236 | wrapper | search | Requesting: count=100, max_id=15353194672485703
74, q=Actualité, tweet_mode=extended, lang=fr
```

Entrée [5]:

```python
python = pd.read_csv('python_tweets.csv',
                     parse_dates=['tweet_created_at', 'user_created_at'])
print(python.shape)
python.head(3)
```

```
(1000, 80)
```

Out[5]:

	tweet_created_at	tweet_id	tweet_id_str	tweet_full_text	tweet_truncated	tweet_display_text_range	tweet_entities	tweet_entities_n
0	2022-06-10 18:49:25+00:00	1535333327909052423	1535333327909052423	RT @DominiqueLUNEL: 📍Ic est vraiment pas de chance😍 Stade...	False	[0, 140]	{'hashtags': [], 'symbols': [], 'user_mentions': [{'scre...	@Dominiqu
1	2022-06-10 18:49:22+00:00	1535333317201088520	1535333317201088520	Warner Bros. redonne vie aux Looney Tunes... en NFT - ht...	False	[0, 116]	{'hashtags': [{'text': 'tech', 'indices': [78, 83]}, {'t...	
2	2022-06-10 18:49:16+00:00	1535333291951329282	1535333291951329282	"Indexation des retraites" sur l'inflation : le slogan t...	False	[0, 103]	{'hashtags': [], 'symbols': [], 'user_mentions': [], 'ur...	

Entrée [7]:
```
(python
 .sort_values(['user_followers_count'], ascending=False)
 [['tweet_full_text', 'user_screen_name',
   'user_followers_count', 'user_description']]
 .head(10))
```

Out[7]:

	tweet_full_text	user_screen_name	user_followers_count	user_description
647	Les images de vidéosurveillance de la RATP ont également...	Le_Figaro	3605909	La culture de la liberté depuis 1826
690	RT @AlbanBty: «Être conservateur, ce n'est pas faire la ...	Le_Figaro	3605909	La culture de la liberté depuis 1826
660	Est-ce une faute de ne pas avoir saisi les vidéos de sur...	Le_Figaro	3605909	La culture de la liberté depuis 1826
364	Ce vendredi, l'Elysée a fait un pas vers ses alliés euro...	LEXPRESS	1453922	S'informer pour réussir\n\nRetrouvez-nous sur :\nFaceboo...
611	En pleine semaine de commémoration du massacre de la pla...	LEXPRESS	1453922	S'informer pour réussir\n\nRetrouvez-nous sur :\nFaceboo...
374	RDC: la tension monte encore entre Kigali et Kinshasa, s...	actualitecd	446304	L'actu congolaise en direct! Média de @nextcorpcd ✚: @De...
488	Roi Philippe aux étudiants de l'UNILU : "le Congo dispos...	actualitecd	446304	L'actu congolaise en direct! Média de @nextcorpcd ✚: @De...
679	Kinshasa : avec l'accompagnement de Bracongo, ETEC Envir...	actualitecd	446304	L'actu congolaise en direct! Média de @nextcorpcd ✚: @De...
301	RT @actualitecd: RDC: la tension monte encore entre Kiga...	actualitecd	446304	L'actu congolaise en direct! Média de @nextcorpcd ✚: @De...
927	RT @actualitecd: RDC: François Beya récuse la Haute cour...	actualitecd	446304	L'actu congolaise en direct! Média de @nextcorpcd ✚: @De...

Entrée [30]:
```
# number of rows - number of duplicates:
python.shape[0] - python['user_id'].duplicated().sum()
```

Out[30]: 275

Entrée [8]:
```
python['user_screen_name'].value_counts().head(10)
```

Out[8]:
```
MaitreWings        18
MAHDI14175          8
Dom972Joe           8
monteaupatrick2     5
directvelo          5
```

Entrée [17]:
```
(available_trends
 [available_trends['name'].duplicated(keep=False)]
 .sort_values(['name']))
```

Out[17]:

	name	url	parentid	country	woeid	countryCode	code	place_type
316	Barcelona	http://where.yahooapis.com/v1/place/753692	23424950	Spain	753692	ES	7	Town
452	Barcelona	http://where.yahooapis.com/v1/place/395273	23424982	Venezuela	395273	VE	7	Town
362	Birmingham	http://where.yahooapis.com/v1/place/12723	23424975	United Kingdom	12723	GB	7	Town
393	Birmingham	http://where.yahooapis.com/v1/place/2364559	23424977	United States	2364559	US	7	Town
306	Singapore	http://where.yahooapis.com/v1/place/23424948	1	Singapore	23424948	SG	12	Country
307	Singapore	http://where.yahooapis.com/v1/place/1062617	23424948	Singapore	1062617	SG	7	Town
324	Valencia	http://where.yahooapis.com/v1/place/776688	23424950	Spain	776688	ES	7	Town
460	Valencia	http://where.yahooapis.com/v1/place/395272	23424982	Venezuela	395272	VE	7	Town

Entrée [20]:
```
france_ids = available_trends.query('country == "France"')
france_ids
```

Out[20]:

	name	url	parentid	country	woeid	countryCode	code	place_type
69	France	http://where.yahooapis.com/v1/place/23424819	1	France	23424819	FR	12	Country
70	Bordeaux	http://where.yahooapis.com/v1/place/580778	23424819	France	580778	FR	7	Town
71	Lille	http://where.yahooapis.com/v1/place/608105	23424819	France	608105	FR	7	Town
72	Lyon	http://where.yahooapis.com/v1/place/609125	23424819	France	609125	FR	7	Town
73	Marseille	http://where.yahooapis.com/v1/place/610264	23424819	France	610264	FR	7	Town
74	Montpellier	http://where.yahooapis.com/v1/place/612977	23424819	France	612977	FR	7	Town
75	Nantes	http://where.yahooapis.com/v1/place/613858	23424819	France	613858	FR	7	Town
76	Paris	http://where.yahooapis.com/v1/place/615702	23424819	France	615702	FR	7	Town

4.2 Analyse et visualisation des tweets

Dans cette section, il s'agit de visualiser pour une éventuelle analyse, les données twitter de deux hommes politiques qui sont trés médiatiques et qui ont un impact dans la société et la vie politique au Sénégal.

4.2.1 Visualisation des tweets de Ousmane Sonko

Entrée [9]:
```
# lire le fichier
pd.read_pickle('Sonko.gzip')
```

Out[9]:

	tweets	id	len	date	source	likes	retweets
0	Chers compatriotes,\n\nJe vous donne rendez-vo...	1528866660433920000	100	2022-05-23 22:33:11	Twitter for iPhone	1924	223
1	#NewProfilePic https://t.co/qFFZVUFkEy	1526923824968650754	38	2022-05-18 13:53:03	Twitter for iPhone	3453	241
2	Nous vous donnons rendez-vous demain au Tribun...	1526715802719817728	140	2022-05-18 00:06:27	Twitter Web App	1172	116
3	J'apporte tout mon soutien à Idrissa Gana Guey...	1526715800165437443	140	2022-05-18 00:06:26	Twitter Web App	3686	858
4	de la décision de la Cour de Cassation. Il rev...	1526715797573447680	140	2022-05-18 00:06:25	Twitter Web App	584	69
5	Elle doit accepter la rectification que Déthié...	1526715795153330177	140	2022-05-18 00:06:25	Twitter Web App	429	60
6	Cependant, cela ne signifie aucunement que la ...	1526715792628252673	140	2022-05-18 00:06:24	Twitter Web App	409	57
7	2-Une fois à la DGE, la fatigue et la faim ont...	1526715790166315010	140	2022-05-18 00:06:24	Twitter Web App	417	56
8	1- Khalifa Sall a tardé de prendre une décisio...	1526715787721023489	140	2022-05-18 00:06:23	Twitter Web App	421	58
9	Il n'y a eu ni complot ni plan de Macky Sall. ...	1526715785363738631	92	2022-05-18 00:06:22	Twitter Web App	790	133
10	Toutes les accusations portées contre Khalifa ...	1526715782733905921	139	2022-05-18 00:06:22	Twitter Web App	444	57
11	J'aurais aimé, par exemple, voir une personne...	1526715780167045122	139	2022-05-18 00:06:21	Twitter Web App	416	59
12	La confection des listes devrait relever de la...	1526715777394561026	140	2022-05-18 00:06:20	Twitter Web App	396	54
13	Cette coalition cristallise l'espoir de tous l...	1526715775112908802	87	2022-05-18 00:06:20	Twitter Web App	491	57
14	Combien de listes se sont vues annulées dans t...	1526715772583698432	140	2022-05-18 00:06:19	Twitter Web App	378	45
15	nous avons décidé de nous prononcer, en compag...	1526715769941331969	139	2022-05-18 00:06:19	Twitter Web App	409	53
16	Nous aimerions préciser, à l'entame de notre p...	1526715767424794625	139	2022-05-18 00:06:18	Twitter Web App	2857	371
17	Chers concitoyens \n\nNous vous donnons rendez...	1526638292472668160	140	2022-05-17 18:58:27	Twitter for iPhone	1910	284
18	De retour ce matin à Ziguinchor, j'ai eu le pl...	1523735812394741760	140	2022-05-09 18:45:01	Twitter for iPhone	6840	589
19	..du 62é anniversaire de notre indépendance po...	1510992106168496139	140	2022-04-04 14:46:05	Twitter for iPhone	903	70

Figure 7: Dataframe des tweets de Ousmane Sonko

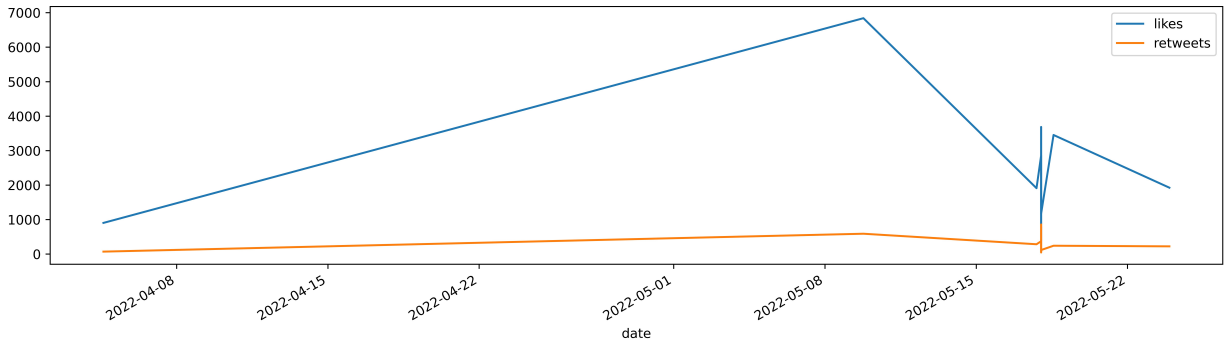

Figure 8: Les courbes d'évolutions des likes et des retweets en fonction de la date

```
Entrée [8]: import seaborn as sns
plt.figure( figsize = ( 10, 8 ) )
sns.barplot( x="likes", y="date", data=df.head(10))
plt.savefig('Visualbarlikes.jpg')
plt.show()
```

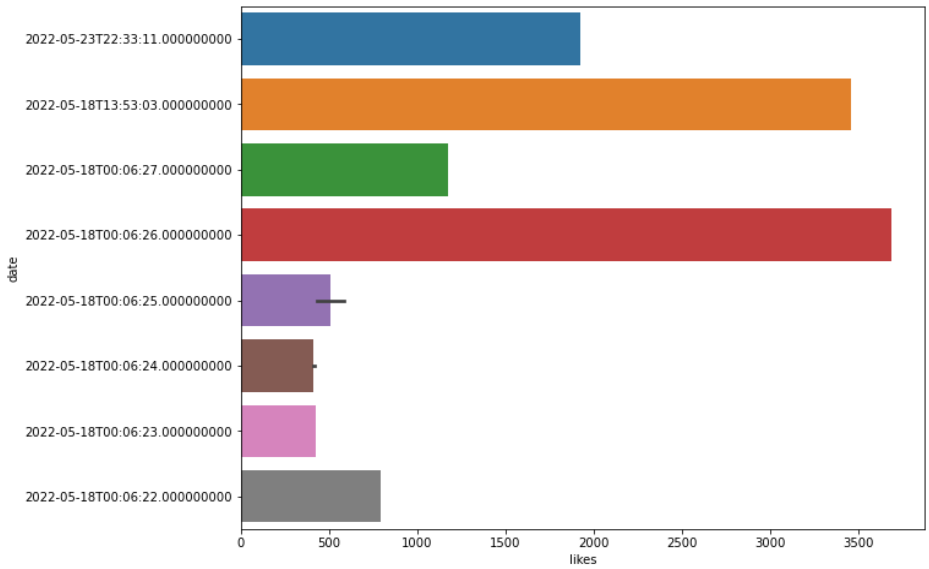

Figure 9: Histogrammes des likes en fonction de la date

```
Entrée [7]: import seaborn as sns
plt.figure( figsize = ( 10, 8 ) )
sns.barplot( x="retweets", y="date", data=df.head(10))
plt.savefig('Visualbaretweets.jpg')
plt.show()
```

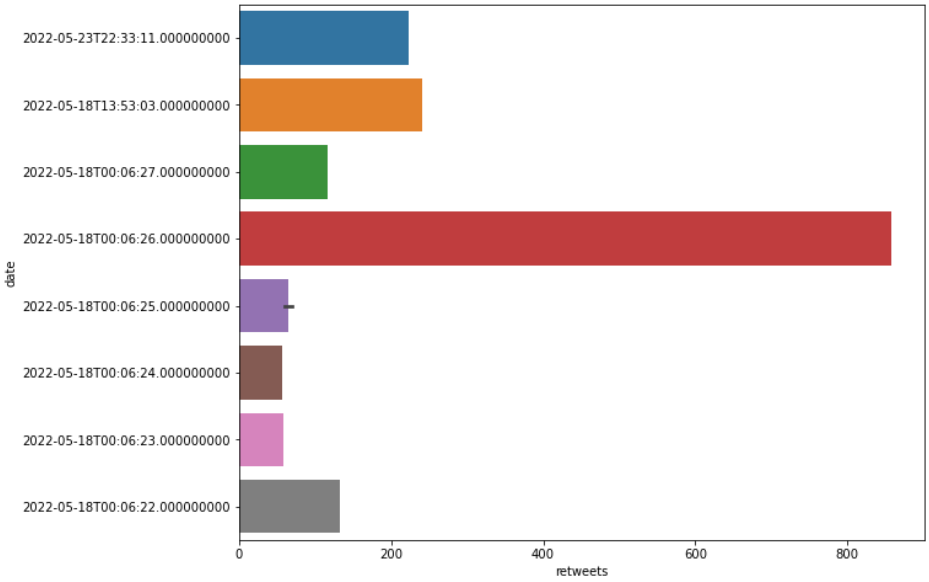

Figure 10: Histogrammes des retweets en fonction de la date

4.2.2 Visualisation des tweets de Macky Sall

Entrée [12]:
```python
# lire le fichier
pd.read_pickle('Macky.gzip')
```

Out[12]:

	tweets	id	len	date	source	likes	retweets
0	I would like to thank President #Putin for his...	1532782632764854272	130	2022-06-03 17:53:52	Twitter for iPhone	253	50
1	President #Putin expressed to us his readiness...	1532782254530994176	139	2022-06-03 17:52:21	Twitter for iPhone	160	31
2	Le Président #Poutine nous a exprimé sa dispon...	1532740261658431489	140	2022-06-03 15:05:29	Twitter for iPhone	1634	309
3	Je remercie le Président #Poutine pour son aim...	1532740240569516034	140	2022-06-03 15:05:24	Twitter for iPhone	4016	630
4	#ConseilDesMinistresSn https://t.co/X6WjbQcv5Z	1532113882017406977	46	2022-06-01 21:36:29	Twitter Web App	275	57
5	Je remercie SEM Seyed Ibrahim Ra'isi, Pdt de l...	1531786181482012672	140	2022-05-31 23:54:19	Twitter for iPhone	1243	94
6	Au nom de l'Union Africaine, je remercie les D...	1531576481498923009	140	2022-05-31 10:01:03	Twitter for iPhone	1584	185
7	Je remercie les Pdts Tshisekedi et Kagame pou...	1531334280516980737	140	2022-05-30 17:58:37	Twitter for iPhone	4866	727
8	Je suis gravement préoccupé par la montée de l...	1530874324084719617	139	2022-05-29 11:30:55	Twitter for iPhone	9371	1436
9	Je tiens à remercier mes chers homologues @Pau...	1530579786921390082	140	2022-05-28 16:00:32	Twitter for iPhone	2388	242
10	Je suis très peiné d'apprendre ce jour le décè...	1529769426572255233	140	2022-05-26 10:20:27	Twitter for iPhone	2472	189
11	Je viens d'apprendre avec douleur et consterna...	1529603434856464384	139	2022-05-25 23:20:52	Twitter for iPhone	9786	1389
12	Je suis venu porter, avec mon frère Lourenço, ...	1529587998106570753	140	2022-05-25 22:19:31	Twitter for iPhone	262	40
13	#SenegalAngola \nJe réitère mes sincères remer...	1529587987796869122	140	2022-05-25 22:19:29	Twitter for iPhone	792	65
14	Congratulations @DrTedros on your re-election ...	1529520489907081217	140	2022-05-25 17:51:16	Twitter for iPhone	580	193
15	#AfricaDay #AfricaDay2022 \nSuivre l'intégrali...	1529495934761148422	107	2022-05-25 16:13:42	Twitter Web App	377	80
16	RT @PR_Senegal: Chaque #25mai, nous fêtons la ...	1529446482260201472	140	2022-05-25 12:57:11	Twitter Web App	0	63
17	Ensemble, continuons le travail. \n\nEnsemble,...	1529390772474331137	140	2022-05-25 09:15:49	Twitter Web App	327	74
18	J'invite particulièrement notre jeunesse à por...	1529390441807986689	125	2022-05-25 09:14:30	Twitter Web App	243	61
19	L'Afrique des routes, des autoroutes, des chem...	1529390264313323520	139	2022-05-25 09:13:48	Twitter Web App	225	53

Figure 11: Dataframe des tweets de Macky Sall

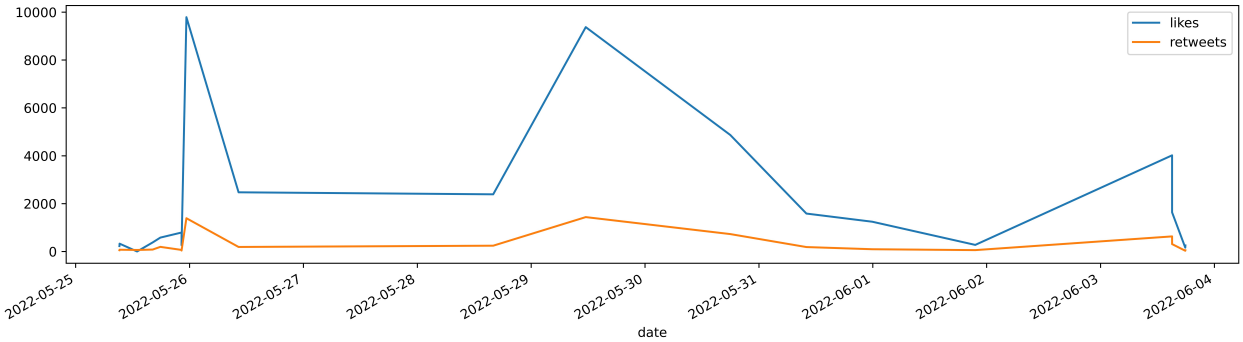

Figure 12: Les courbes d'évolutions des likes et des retweets en fonction de la date

```
Entrée [13]: import seaborn as sns
plt.figure( figsize = ( 10, 8 ) )
sns.barplot( x="retweets", y="date", data=df.head(10))
plt.savefig('Visualbaretweets.jpg')
plt.show()
```

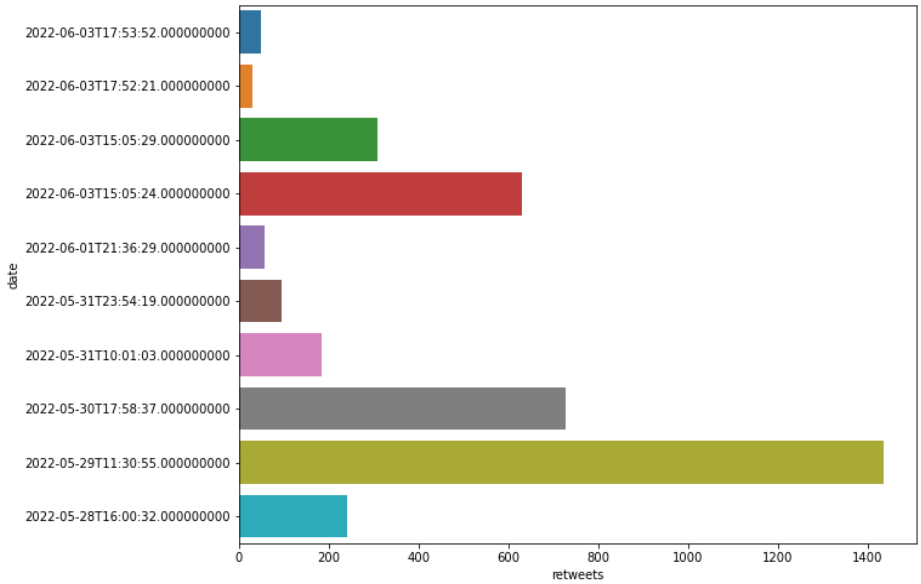

Figure 13: Histogrammes des likes en fonction de la date

```
Entrée [14]: import seaborn as sns
plt.figure( figsize = ( 10, 8 ) )
sns.barplot( x="likes", y="date", data=df.head(10))
plt.savefig('Visualbarlikes.jpg')
plt.show()
```

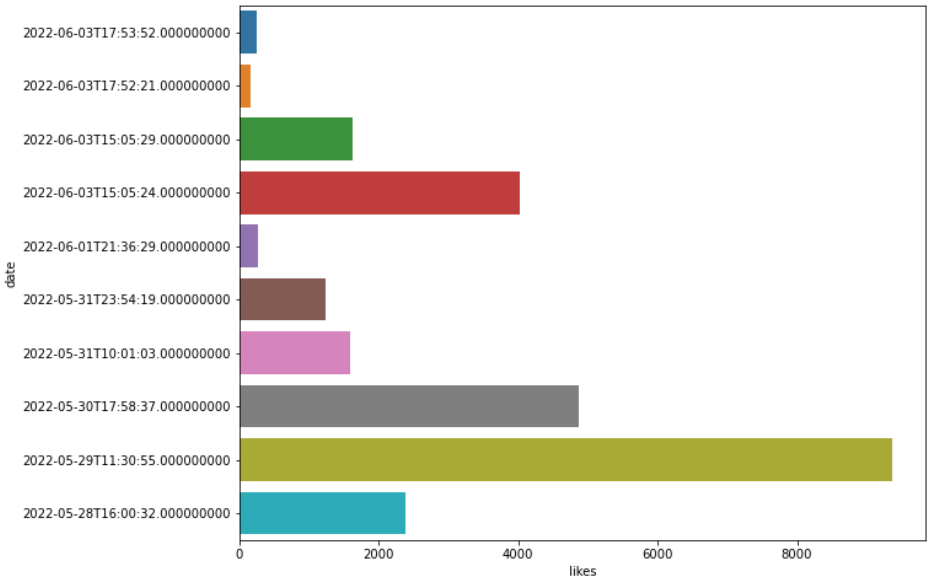

Figure 14: Histogrammes des retweets en fonction de la date

4.3 Analyse des sentiments des données tweets

Qu'est-ce que l'analyse des sentiments?

L'analyse des sentiments est le processus qui consiste à déterminer «par ordinateur» si une écriture est positive, négative ou neutre. Il est également connu sous le nom de mine d'opinion , dérivant de l'opinion ou de l'attitude d'un orateur.
En Python, la bibliothèque **textblob** est utilisée pour le traitement des données textuelles.

Pourquoi l'analyse des sentiments?

- **Affaires:** dans le domaine du marketing, les entreprises l'utilisent pour développer leurs stratégies, pour comprendre les sentiments des clients envers les produits ou la marque, comment les gens réagissent à leurs campagnes ou lancements de produits et pourquoi les consommateurs n'achètent pas certains produits.

- **Politique:** dans le domaine politique, il est utilisé pour suivre les opinions politiques, pour détecter la cohérence et l'incohérence entre les déclarations et les actions au niveau gouvernemental. Il peut également être utilisé pour prédire les résultats des élections.

- **Actions publiques:** l' analyse des sentiments est également utilisée pour surveiller et analyser les phénomènes sociaux, pour repérer des situations potentiellement dangereuses et pour déterminer l'humeur générale de la blogosphère.

Le module NLP TextBlob pour l'analyse de sentiments

Le Natural Language Processing (NLP)est la discipline du machine learning liée à la compréhension du langage par les machines. Les dernières avancées dans ce domaine ont permis l'émergence d'applications intéressantes et effrayantes aussi.
Textblob est un module NLP sur Python utilisé pour l'analyse de sentiment. La fonction de TextBlob qui nous intéresse permet pour un texte donné de déterminer le ton du texte et le sentiment de la personne qui l'a écrit.
Pour chaque tweet nous aurons une métrique qui donne la polarité de ce tweet grâce à un classificateur de sentiment qui classe le sentiment du tweet comme positif, négatif ou neutre en lui attribuant une polarité respective 1, -1 ou 0.

4.3.1 Analyse des sentiments des tweets de Ousmane Sonko

Entrée [2]:
```
# lire le fichier
pd.read_pickle('Sonko.gzip')
```

Out[2]:

	tweets	id	len	date	source	likes	retweets	sentiment
0	Chers compatriotes,\n\nJe vous donne rendez-vo...	1528866660433920000	100	2022-05-23 22:33:11	Twitter for iPhone	1928	223	0
1	#NewProfilePic https://t.co/qFFZVUFkEy	1526923824968650754	38	2022-05-18 13:53:03	Twitter for iPhone	3458	242	0
2	Nous vous donnons rendez-vous demain au Tribun...	1526715802719817728	140	2022-05-18 00:06:27	Twitter Web App	1173	116	0
3	J'apporte tout mon soutien à Idrissa Gana Guey...	1526715800165437443	140	2022-05-18 00:06:26	Twitter Web App	3690	860	0
4	de la décision de la Cour de Cassation. Il rev...	1526715797573447680	140	2022-05-18 00:06:25	Twitter Web App	584	69	0
...	...	...	...	...	...	...	...	...
195	Que chaque jeune vérifie dès à présent son sta...	1423674201001574407	140	2021-08-06 15:55:54	Twitter Web App	149	41	0
196	Que les personnes détentrices de cartes d'iden...	1423674198782775300	140	2021-08-06 15:55:54	Twitter Web App	145	36	0
197	Que les personnes qui n'avaient pas retiré leu...	1423674196580786177	140	2021-08-06 15:55:53	Twitter Web App	135	32	0
198	Que les moins de 18 ans, et qui atteindront l'...	1423674194131361794	140	2021-08-06 15:55:53	Twitter Web App	147	31	0
199	À cet effet, ceux qui auront l'honneur d'exerc...	1423674192382369796	139	2021-08-06 15:55:52	Twitter Web App	122	15	0

200 rows × 8 columns

Figure 15: Dataframe des sentiments de Ousmane Sonko par tweet

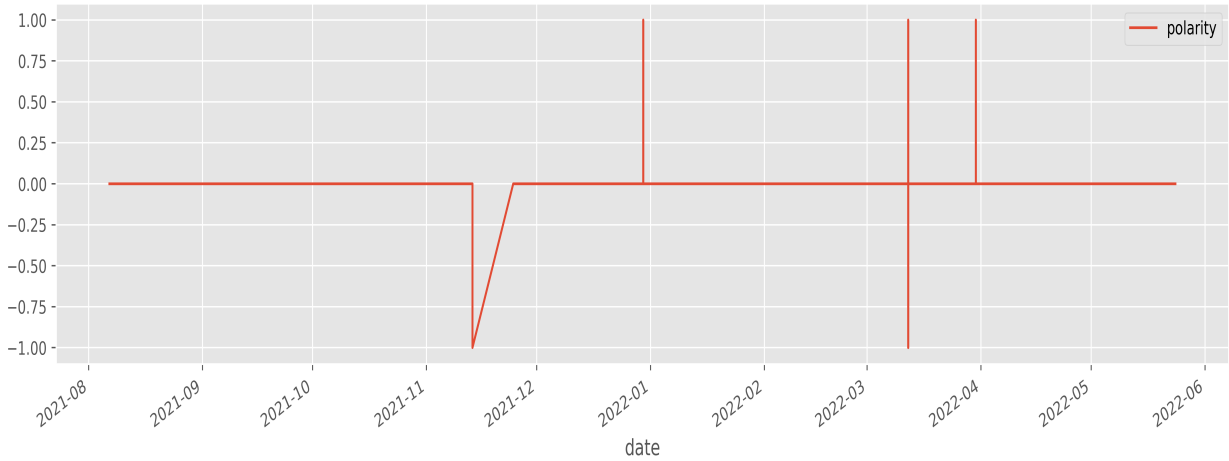

Figure 16: Courbe d'évolution de la polarité des sentiments en fonction de la date

4.3.2 Analyse des sentiments des tweets de Macky Sall

```
Entrée [2]: # lire le fichier
            pd.read_pickle('Macky.gzip')
```

Out[2]:

	tweets	id	len	date	source	likes	retweets	sentiment
0	Je prends part ce samedi 4 juin, à Accra, au ...	1533086046312882177	140	2022-06-04 13:59:31	Twitter for iPhone	383	47	0
1	Je félicite le khalife des Niassénes Cheikh Mo...	1532871216607944704	140	2022-06-03 23:45:52	Twitter for iPhone	3928	406	0
2	President #Putin expressed to us his readiness...	1532815016998719488	140	2022-06-03 20:02:33	Twitter for iPhone	672	163	1
3	I would like to thank President #Putin for his...	1532782632764854272	130	2022-06-03 17:53:52	Twitter for iPhone	917	202	1
4	Le Président #Poutine nous a exprimé sa dispon...	1532740261658431489	140	2022-06-03 15:05:29	Twitter for iPhone	3218	611	0
...	...	...	...	...	...	...	...	...
195	RT @PR_Senegal: Le Président de la République ...	1495797357362954249	140	2022-02-21 16:27:35	Twitter for iPhone	0	95	0
196	Au terme de ce sommet Union européenne-Union a...	1494717209524023299	140	2022-02-18 16:55:27	Twitter Web App	501	107	0
197	📌#EUAUSummit \n🗣 Conférence de presse avec @...	1494666500740943875	132	2022-02-18 13:33:57	Twitter for iPhone	184	54	0
198	Cette Afrique en pleine mutation veut des part...	1494434767005171719	140	2022-02-17 22:13:08	Twitter for iPhone	591	117	0
199	A l'ère des complémentarités et des interdépen...	1494372288380166147	140	2022-02-17 18:04:52	Twitter for iPhone	531	111	0

200 rows × 8 columns

Figure 17: Dataframe des sentiments de Macky Sall par tweet

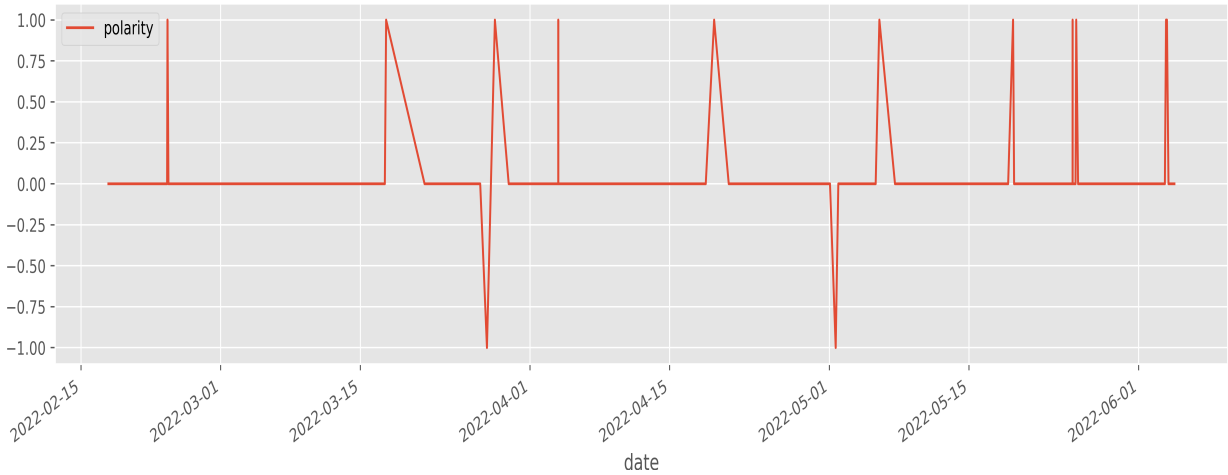

Figure 18: Courbe d'évolution de la polarité des sentiments en fonction de la date

5 Conclusion

Le traitement et l'analyse des tweets effectués dans ce rapport, nous confirme que Python posséde un écosystéme performant, Cependant, il faut noter que Apache Spark est le moteur de traitement de données rapide dédié au Big Data. Il permet d'effectuer un traitement de larges volumes de données de manière distribuée (cluster computing) afin de les analyser.
Très en vogue depuis maintenant quelques années, ce Framework est en passe de remplacer Hadoop. Ses principaux avantages sont sa vitesse, sa simplicité d'usage, et sa polyvalence.

6 Annexe: Les scriptes en Python

6.1 Annexe 1: Streamer les tweets et stockage

```
from tweepy.streaming import StreamListener
from tweepy import OAuthHandler
from tweepy import Stream
# import twitter_credentials
# Variables that contains the user credentials to access Twitter API
ACCESS_TOKEN ="1511746246494593032-u3t18TrXTsBT5SNqwh7yRNx1RW7AmA"
ACCESS_TOKEN_SECRET ="3JJzKQFI7O5lu2qs4ks4sQQn1ximGeKMYUPJg5sFgtpyb"
CONSUMER_KEY ="k8WtNYDfJt7D5WYX4KKQ2CqFM"
CONSUMER_SECRET ="wmz9QIFnpXQa7jsFmHypOb8koAygZvdWNbWDVKWBcx5WAnSAW2"

# # # # TWITTER STREAMER # # # #
class TwitterStreamer():
"""
Class for streaming and processing live tweets.
"""
def __init__(self):
    pass

def stream_tweets(self, fetched_tweets_filename, hash_tag_list):
# This handles Twitter authetification and the connection to
    # Twitter Streaming API
    listener = StdOutListener(fetched_tweets_filename)
    auth = OAuthHandler(CONSUMER_KEY,CONSUMER_SECRET)
    auth.set_access_token(ACCESS_TOKEN, ACCESS_TOKEN_SECRET)
    stream = Stream(auth, listener)
# This line filter Twitter Streams to capture data by the keywords:
    stream.filter(track=hash_tag_list)

# # # # TWITTER STREAM LISTENER # # # #
class StdOutListener(StreamListener):
    """
    This is a basic listener that just prints received tweets to stdout.
    """
    def __init__(self, fetched_tweets_filename):
        self.fetched_tweets_filename = fetched_tweets_filename

    def on_data(self, data):
        try:
            print(data)
            with open(self.fetched_tweets_filename, 'a') as tf:
                tf.write(data)
            return True
        except BaseException as e:
            print("Error␣on_data␣%s" % str(e))
```

```
        return True
    def on_error(self, status):
        print(status)
if __name__ == '__main__':

# Authenticate using config.py and connect to Twitter Streaming API.
hash_tag_list = ["Macky␣Sall","Ousmane␣Sonko","Khalifa␣Sall","Barthelemy␣Dias"]
fetched_tweets_filename="tweets.txt" #  ou en tweets.csv
twitter_streamer = TwitterStreamer()
twitter_streamer.stream_tweets(fetched_tweets_filename, hash_tag_list)
```

6.2 Annexe 2: Streamer puis stocker les tweets en dataframe

```
 import pandas as pd
pd.set_option('display.max_colwidth', 60)
pd.set_option('display.max.columns', None) # 70+ columns to explore!
# get these from your dashboard on developer.twitter.com:
auth_params = {
    'app_key': "k8WtNYDfJt7D5WYX4KKQ2CqFM",
    'app_secret': "wmz9QIFnpXQa7jsFmHypOb8koAygZvdWNbWDVKWBcx5WAnSAW2",
    'oauth_token':"1511746246494593032-u3t18TrXTsBT5SNqwh7yRNx1RW7AmA",
    'oauth_token_secret': "3JJzKQFI7O5lu2qs4ks4sQQn1ximGeKMYUPJg5sFgtpyb",
}

# twython:
from twython import Twython
twitter = Twython(**auth_params)
twitter.search(q='Actualit ')
# or any other function and / or parameters

# advertools:
import advertools as adv
adv.twitter.set_auth_params(**auth_params)
adv.twitter.get_user_timeline(screen_name='twitter')
# or some other function
python=adv.twitter.search(q='Actualit ',count=1000,
                          tweet_mode='extended',lang='fr')
python.to_csv('python_tweets.csv', index=False)
```

6.3 Annexe 3:Analyse et visualisation des données tweets

```
from tweepy import API
from tweepy import Cursor
from tweepy.streaming import StreamListener
from tweepy import OAuthHandler
from tweepy import Stream

import twitter_credentials
import numpy as np
```

```
import pandas as pd
import matplotlib.pyplot as plt

ACCESS_TOKEN ="1511746246494593032-u3t18TrXTsBT5SNqwh7yRNx1RW7AmA"
ACCESS_TOKEN_SECRET ="3JJzKQFI7O5lu2qs4ks4sQQn1ximGeKMYUPJg5sFgtpyb"
CONSUMER_KEY ="k8WtNYDfJt7D5WYX4KKQ2CqFM"
CONSUMER_SECRET ="wmz9QIFnpXQa7jsFmHypOb8koAygZvdWNbWDVKWBcx5WAnSAW2"
# # # # TWITTER CLIENT # # # #
class TwitterClient():
 def __init__(self, twitter_user=None):
    self.auth = TwitterAuthenticator().authenticate_twitter_app()
    self.twitter_client = API(self.auth)

    self.twitter_user = twitter_user

 def get_twitter_client_api(self):
        return self.twitter_client

 def get_user_timeline_tweets(self, num_tweets):
    tweets = []
    for tweet in Cursor(self.twitter_client.user_timeline, id=self.twitter_user)
                            .items(num_tweets):
    tweets.append(tweet)
       return tweets

 def get_friend_list(self, num_friends):
    friend_list = []
    for friend in Cursor(self.twitter_client.friends, id=self.twitter_user)
                             .items(num_friends):
    friend_list.append(friend)
        return friend_list

 def get_home_timeline_tweets(self, num_tweets):
    home_timeline_tweets = []
    for tweet in Cursor(self.twitter_client.home_timeline, id=self.twitter_user)
                                .items(num_tweets):
    home_timeline_tweets.append(tweet)
        return home_timeline_tweets


# # # # TWITTER AUTHENTICATER # # # #
class TwitterAuthenticator():

    def authenticate_twitter_app(self):
        auth = OAuthHandler(CONSUMER_KEY,CONSUMER_SECRET)
        auth.set_access_token(ACCESS_TOKEN, ACCESS_TOKEN_SECRET)
        return auth

# # # # TWITTER STREAMER # # # #
```

```
class TwitterStreamer():
    """
    Class for streaming and processing live tweets.
    """
    def __init__(self):
        self.twitter_autenticator = TwitterAuthenticator()

    def stream_tweets(self, fetched_tweets_filename, hash_tag_list):
# This handles Twitter authetification and the connection
  #     to Twitter Streaming API
    listener = TwitterListener(fetched_tweets_filename)
    auth = self.twitter_autenticator.authenticate_twitter_app()
    stream = Stream(auth, listener)

 # This line filter Twitter Streams to capture data by the keywords:
        stream.filter(track=hash_tag_list)


# # # # TWITTER STREAM LISTENER # # # #
class TwitterListener(StreamListener):
    """
    This is a basic listener that just prints received tweets to stdout.
    """
    def __init__(self, fetched_tweets_filename):
        self.fetched_tweets_filename = fetched_tweets_filename

    def on_data(self, data):
        try:
            print(data)
            with open(self.fetched_tweets_filename, 'a') as tf:
                tf.write(data)
            return True
        except BaseException as e:
            print("Error␣on_data␣%s" % str(e))
        return True

    def on_error(self, status):
        if status == 420:
            # Returning False on_data method in case rate limit occurs.
            return False
        print(status)


class TweetAnalyzer():
    """
    Functionality for analyzing and categorizing content from tweets.
    """
def tweets_to_data_frame(self, tweets):
  df = pd.DataFrame(data=[tweet.text for tweet in tweets], columns=['tweets'])
```

```
        df['id'] = np.array([tweet.id for tweet in tweets])
        df['len'] = np.array([len(tweet.text) for tweet in tweets])
        df['date'] = np.array([tweet.created_at for tweet in tweets])
        df['source'] = np.array([tweet.source for tweet in tweets])
        df['likes'] = np.array([tweet.favorite_count for tweet in tweets])
        df['retweets'] = np.array([tweet.retweet_count for tweet in tweets])

        return df

if __name__ == '__main__':

    twitter_client = TwitterClient()
    tweet_analyzer = TweetAnalyzer()

    api = twitter_client.get_twitter_client_api()

    tweets = api.user_timeline(screen_name="@Macky_Sall", count=20)

    print(dir(tweets[0]))
    print(tweets[0].retweet_count)

    df = tweet_analyzer.tweets_to_data_frame(tweets)
    # enregistrer les donnees
    df.to_pickle('Macky.gzip')
   # lire le fichier
    pd.read_pickle('Macky.gzip')
    # Get average length over all tweets:
    print(np.mean(df['len']))

    # Get the number of likes for the most liked tweet:
    print(np.max(df['likes']))

    # Get the number of retweets for the most retweeted tweet:
    print(np.max(df['retweets']))

    print(df.head(10))

    # Time Series
    #time_likes = pd.Series(data=df['len'].values, index=df['date'])
    #time_likes.plot(figsize=(16, 4), color='r')
    #plt.show()

    time_favs = pd.Series(data=df['likes'].values, index=df['date'])
    time_favs.plot(figsize=(16, 4), color='r')
    plt.show()
    plt.savefig('Visuallikes.jpg',dpi=800, quality=90, optimize=True,
                                progressive=True)
```

```
    time_retweets = pd.Series(data=df['retweets'].values, index=df['date'])
    time_retweets.plot(figsize=(16, 4), color='r')
    plt.savefig('Visualretweets.jpg',dpi=800, quality=90, optimize=True,
                                progressive=True)
    plt.show()

    # Layered Time Series:
    time_likes = pd.Series(data=df['likes'].values, index=df['date'])
    time_likes.plot(figsize=(16, 4), label="likes", legend=True)
    plt.savefig('VisualLikes.jpg',dpi=800, quality=90, optimize=True,
                               progressive=True)

    time_retweets = pd.Series(data=df['retweets'].values, index=df['date'])
    time_retweets.plot(figsize=(16, 4), label="retweets", legend=True)
    plt.savefig('VisualRetweets.jpg',dpi=800, quality=90, optimize=True,
                              progressive=True)
    plt.show()
```

6.4 Annexe 4: Analyse des sentiments des données tweets

```
 from tweepy import API
from tweepy import Cursor
from tweepy.streaming import StreamListener
from tweepy import OAuthHandler
from tweepy import Stream

from textblob import TextBlob

#import twitter_credentials

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import re

ACCESS_TOKEN ="1511746246494593032-u3t18TrXTsBT5SNqwh7yRNx1RW7AmA"
ACCESS_TOKEN_SECRET ="3JJzKQFI7O5lu2qs4ks4sQQn1ximGeKMYUPJg5sFgtpyb"
CONSUMER_KEY ="k8WtNYDfJt7D5WYX4KKQ2CqFM"
CONSUMER_SECRET ="wmz9QIFnpXQa7jsFmHypOb8koAygZvdWNbWDVKWBcx5WAnSAW2"

# # # # TWITTER CLIENT # # # #
class TwitterClient():
def __init__(self, twitter_user=None):
    self.auth = TwitterAuthenticator().authenticate_twitter_app()
    self.twitter_client = API(self.auth)

    self.twitter_user = twitter_user

def get_twitter_client_api(self):
```

```
    return self.twitter_client

def get_user_timeline_tweets(self, num_tweets):
    tweets = []
    for tweet in Cursor(self.twitter_client.user_timeline,
                        id=self.twitter_user).items(num_tweets):
    tweets.append(tweet)
      return tweets

def get_friend_list(self, num_friends):
 friend_list = []
 for friend in Cursor(self.twitter_client.friends,
                      id=self.twitter_user).items(num_friends):
 friend_list.append(friend)
    return friend_list

def get_home_timeline_tweets(self, num_tweets):
  home_timeline_tweets = []
  for tweet in Cursor(self.twitter_client.home_timeline,
                      id=self.twitter_user).items(num_tweets):
  home_timeline_tweets.append(tweet)
   return home_timeline_tweets


# # # # TWITTER AUTHENTICATER # # # #
class TwitterAuthenticator():

    def authenticate_twitter_app(self):
        auth = OAuthHandler(CONSUMER_KEY, CONSUMER_SECRET)
        auth.set_access_token(ACCESS_TOKEN,ACCESS_TOKEN_SECRET)
        return auth

# # # # TWITTER STREAMER # # # #
class TwitterStreamer():
    """
    Class for streaming and processing live tweets.
    """
    def __init__(self):
        self.twitter_autenticator = TwitterAuthenticator()

    def stream_tweets(self, fetched_tweets_filename, hash_tag_list):
        # This handles Twitter authetification and the connection
         #     to Twitter Streaming API
        listener = TwitterListener(fetched_tweets_filename)
        auth = self.twitter_autenticator.authenticate_twitter_app()
        stream = Stream(auth, listener)

        # This line filter Twitter Streams to capture data by the keywords:
        stream.filter(track=hash_tag_list)
```

```
# # # # TWITTER STREAM LISTENER # # # #
class TwitterListener(StreamListener):
    """
    This is a basic listener that just prints received tweets to stdout.
    """
def __init__(self, fetched_tweets_filename):
self.fetched_tweets_filename = fetched_tweets_filename

def on_data(self, data):
    try:
         print(data)
         with open(self.fetched_tweets_filename, 'a') as tf:
            tf.write(data)
        return True
        except BaseException as e:
            print("Error␣on_data␣%s" % str(e))
        return True

    def on_error(self, status):
        if status == 420:
            # Returning False on_data method in case rate limit occurs.
            return False
        print(status)


class TweetAnalyzer():
    """
    Functionality for analyzing and categorizing content from tweets.
    """

def clean_tweet(self, tweet):
 return '␣'.join(re.sub("(@[A-Za-z0-9]+)|([^0-9A-Za-z␣\t])|(\w+:\/\/\S+)",
                            "␣", tweet).split())

def analyze_sentiment(self, tweet):
  analysis = TextBlob(self.clean_tweet(tweet))

     if analysis.sentiment.polarity > 0:
        return 1
     elif analysis.sentiment.polarity == 0:
        return 0
     else:
        return -1

def tweets_to_data_frame(self, tweets):
 df = pd.DataFrame(data=[tweet.text for tweet in tweets], columns=['tweets'])
```

```
 df['id'] = np.array([tweet.id for tweet in tweets])
 df['len'] = np.array([len(tweet.text) for tweet in tweets])
 df['date'] = np.array([tweet.created_at for tweet in tweets])
 df['source'] = np.array([tweet.source for tweet in tweets])
 df['likes'] = np.array([tweet.favorite_count for tweet in tweets])
 df['retweets'] = np.array([tweet.retweet_count for tweet in tweets])

 return df

if __name__ == '__main__':

 twitter_client = TwitterClient()
 tweet_analyzer = TweetAnalyzer()

api = twitter_client.get_twitter_client_api()

tweets = api.user_timeline(screen_name="@SonkoOfficiel", count=200)

df = tweet_analyzer.tweets_to_data_frame(tweets)
df['sentiment'] = np.array([tweet_analyzer.analyze_sentiment(tweet)
                            for tweet in df['tweets']])
# enregistrer les donnees
df.to_pickle('Sonko.gzip')
# lire le fichier
pd.read_pickle('Sonko.gzip')
print(df.head(10))
```